划分与基本评价

把学习、选择和最终检查分开

机器学习课程学生讲义

辅修版 · 2026 年 10 月 4 日

学生讲义 · 辅修版 · 2026-10-05

对应 T02（2 理论学时）与 B01（2 实验学时）。先学习 T01，本章不要求完成主专业 D01。

导读

T01 已经建立了一个预测流程：明确任务，整理预测时点可取得的输入，用历史数据形成规则，对新对象预测，再用后来取得的实际结果评价。这个流程留下了一个问题：如果评价结果让我们决定修改方法，修改后的方法应当用什么数据来检查?

假设两个能耗预测方法都在同一批新记录上计算了误差，我们选择其中误差较小的方法。虽然这些记录没有用于训练模型，但它们的结果已经影响了我们的选择。若继续用这些结果修改方法，最终评价就不再独立于选择过程。本章将把“从数据中学习”“根据结果选择方法”和“方案确定后的最终检查”区分开，并说明怎样用指标完成有依据的比较。划分数据时，评价条件需要对应实际使用场景。例如，当需要检验对未来批次的预测时，应使用较早记录形成规则和比较方法，再用较晚记录作最终检查，不能忽略时间顺序。

用已经熟悉的语言概括，本章要安排的是：

> 先留好不同用途的数据 → 用其中一部分形成预测规则 → 在另一部分上比较方法 → 确定方案后，再用保留数据作最终检查。

理论课 T02 通过流程判断和小表计算理解这些安排。学习后，你应能解释训练、验证、测试的分工，按任务判断划分方式，计算 MAE、RMSE 和基本分类指标，并说明一个比较结果能够支持什么结论。实验 B01 将把其中的训练与验证流程落实到代码。B01 没有独立最终测试集，这一点也是解释结果的一部分。

1. 训练表现为何不能代替新数据表现

1.1 规则曾经接触过哪些结果

训练模型时，历史样本的特征和标签共同参与训练过程。例如，T01 的均值基线用四个历史批次的能耗确定常数 200。一个更灵活的方法则可能根据历史记录调整预测规则，使这些记录上的误

差变小。模型训练完成后，我们当然可以检查它在这些历史样本上预测得怎样，这得到的是训练误差。

训练误差描述的是模型对参与学习的训练数据的拟合程度。这里的“拟合”指的是让模型的预测与训练数据中的结果相吻合。模型已经利用过这些结果，因此较低的训练误差可能来自两方面：一是模型学习到了能够用于新对象的关系，二是模型适应了训练数据中不能应用于新对象的随机波动或偶然模式。相对于我们希望模型学习到的关系，这些随机干扰通常称为噪声。模型过度适应训练数据中的噪声或特有细节，导致其在训练数据上表现很好，却在新数据上表现较差的现象称为过拟合。

一个极端的例子是模型记住每个历史批次的答案：遇到相同的计划产量时就返回对应的能耗。这个例子的训练误差为 0，但面对一个计划产量不在历史记录中的新批次，它完全没有预测能力。因此，仅凭训练误差无法有效区分模型是否学到了真正有效的关系。实际情况一般没有这么极端，而是将二者混合起来，即模型通常同时学习到了真正有效的关系和噪声。这个例子只是把问题显露出来：模型能够较好地预测参与训练的对象的标签，和能够较好地预测新对象的标签，是两件事，需要不同的证据。

1.2 用未参与训练的记录检查泛化

我们希望学到的关系能够用于训练记录之外的新对象。这种把已学规则用于新对象的能力，称为泛化能力。要取得模型具有泛化能力的证据，就需要在模型没有训练过的记录上作预测，再核对结果。

对于一份完整的历史数据，一个比较通用的办法是先将其中一部分划分出来。虽然我们有这部分数据的真实标签记录，但在训练时不使用这部分记录，训练完成后用这部分数据模拟新对象进行预测，并用标签核对结果。这样划分数据虽然无法把过去的记录变成真实的未来数据，却能建立一个明确条件：模型预测这些对象时，没有用它们的答案训练自身。因此，可以用它相对有效地评估模型的泛化能力。

要注意的是，这一条件并不足以保证模型在所有未来环境中都有效。例如预测来自相同稳定生产过程的新批次，与预测来自新设备或新月份的批次，可能是难度完全不同的问题。最理想的场景下，划分出的数据应该与准备应用模型的数据具有类似的性质。评价的对象和划分方式，应由任务决定。

2. 训练、验证与测试承担不同工作

2.1 训练集用来训练模型

按用途划分数据以后，用于训练模型的那部分，称为训练集。均值基线模型在训练集上通过计算标签的平均值决定预测常数，其他模型也在训练集上学习。训练集既有输入，也有与输入对应的真实结果。

T01 中的训练批次的能耗为 100、150、250、300 kWh，均值就是 200 kWh。另外两个保留批次的能耗 230、320 kWh 虽然已知，却不参与训练。如果把六个值一起平均，常数会变成 225 kWh，但这时六个批次就全部变成了训练批次。规则看似仍很简单，数据的用途却已经改变。

所以，在实际进行训练之前，应先完成数据划分。然后根据训练部分的标签确定基线，而不是先用全部标签计算预测常数，再把记录分开。后续学习需要从数据估计数值的处理方法时，同样要检查这些数值由哪一部分数据确定。

2.2 验证集用来比较与选择模型

训练完成后，通常还有一些额外的决策要做，例如使用简单基线模型还是候选模型，某种方法是否值得保留，或者是否需要调整方案。在 1.2 已经说明，需要用未参与训练的记录检查预测表现。这里，如果进一步利用这些结果比较和选择模型，这些没有参与训练，而是用于比较和选择的记录集合就称为验证集。每个候选模型都应该在训练集上完成学习，然后在同一验证集上给出预测，最后核对与验证集真实标签的一致性。

验证标签并没有参与模型的训练，但验证结果会影响我们的决策。比如，候选模型 A 的验证 MAE 为 15 kWh，候选模型 B 为 40 kWh，我们据此选择候选模型 A。但是要注意，因为选择过程依赖验证集，因此这个验证结果虽然可以作为选择的依据，却不能被描述为完全独立于选择过程的最终检查。

如果我们反复依据验证结果修改模型或训练方法，最终方案可能越来越适应这批验证记录。即使验证标签没有直接参与模型训练，我们对新数据表现的判断也可能因此偏向乐观。所以，验证结果可以用于改进和选择，但不能同时被当作独立最终检查，方案确定后仍然需要另一份独立数据来进行最终评价。

2.3 测试集用于方案确定后的最终检查

除了训练集和验证集之外，还可以再留出一部分数据，这部分数据既不参与训练，也不参与选择。而是在输入方案、候选模型和评价方法确定后，用于最后的检查。这部分数据被称为测试集。因此，本课程所说的测试，含有独立最终检查的意思，而不只是“在任何没用于训练的数据上算一次分数”。

既然是独立最终检查，就需要避免利用测试结果继续挑选方法，尤其是在据此更新模型后再次在测试集上检验。例如看到测试误差偏高后换一个模型，再看测试分数。这种行为实际上等价于让测试集承担了选择用途。

取得测试结果后仍然可以继续研究问题、开发新版本的模型。不过，如果测试结果被用于研发新一轮的改进，就需要重新说明评价安排，为新方案准备独立检查，而不是继续沿用旧“测试集”这个名称来声明结果独立。数据的角色取决于实际用法。

2.4 三种数据集的对比

三种用途可以归纳为：

数据部分	主要工作	结果如何影响方案
训练集	确定参数或预测规则	直接参与模型形成
验证集	比较候选、支持选择与调整	参与方案选择
测试集	方案确定后的独立最终检查	不用于这次方案选择

再次强调，数据的角色取决于实际用法，而不是不变的身份。如果旧测试结果被用于比较和选择下一版方案，它就承担了验证用途；如果把其中的样本和标签加入模型训练，它就承担了训练用途。此外，反复查看验证成绩并据此修改模型，虽然不意味着这些记录被直接用于训练，但是仍然会削弱它们作为独立评价证据的价值。

3. 数据划分方式取决于预测任务的结构

3.1 随机划分

随机划分把记录随机分配到不同的数据集，减少原有排列方式对分组造成的系统性影响。但随机只是分配方式，不能自动保证评价合理。随机划分的合理性依然取决于记录之间的关系，以及任务的预测目标。

B01 使用 120 个独立合成批次。它们由同一个稳定过程生成，不包含设备重复记录或时间变化趋势，因此适合采用随机划分：80 个批次用于训练，40 个批次用于验证。但是随机划分的合理性仅基于这个教学数据集的性质，不应直接推广到其他数据集。

在随机划分确定后，不同的模型应使用相同的训练集和验证集，这样比较条件才容易对齐。固定随机种子可以在数据内容、行顺序和划分设置不变时，复现相同分组，即每次重新运行得到分组完全相同。但随机种子不是模型的参数，如果不停更换种子，直到出现满意分数，并只报告这次分数，就相当于根据结果挑选检查条件。

3.2 按记录随机划分，不一定保证合理性

假设有两台设备 A 和 B，每天各有一行记录。现在任务是预测全新设备 C 的情况。如果随机分配，可能出现这样的情况：设备 A 的周一记录在训练集中，而周二记录在验证集中。这两行记录虽然编号不同，内容不同，却仍然包含同一台设备。

同一设备可能具有独特的运行习惯和能耗特点。如果设备 A 的记录同时出现在训练集和验证集中，模型就可能利用已经接触过的设备特点预测它的新记录。这样的验证未必能说明模型对全新设备表现怎样。为模拟后一种任务，可以用 A 的全部记录训练，用 B 的全部记录验证，使同一设备的记录留在同一部分。

因此，检查任务中的真实对象有没有跨越训练与评价部分是评价划分的重要一环。不同的任务需要做出不同的安排，关键是评价所模拟的使用方式应与任务一致。

3.3 预测未来时要保留时间方向

如果任务是在月底预测下个月的能耗，实际运行时只能利用当前和过去月份的数据。评价也应尽量模拟这个条件：用较早时期的记录训练，再用较晚时期检查。把未来月份放入训练集中、再评价过去月份，虽然输入字段看似合理，却无法保证与实际任务的一致性。

同样，开工前的能耗预测不能使用完工后才能获取的最终电费。虽然电费在历史表中可能与能耗高度相关，但它在预测时点是未来数据，无法获得，因而不能作为模型输入。更一般地，如果模型训练或选择利用了真实预测时无法取得的信息，或者原本用于独立最终检查的测试结果参与了模型训练与选择，信息就越过了预定的使用边界。这类问题称为数据泄漏，可能使评价结果过于乐观，无法可靠反映模型在目标场景中的预测能力。

4. 用 MAE 与 RMSE 观察回归误差

4.1 同一组预测误差可以用不同指标汇总

T01 使用 MAE，即每个样本绝对误差的平均值，作为评价指标。它的含义很直观：在这批检查对象上，预测与实际平均相差多少。另一种常见汇总先平方每个误差，取平均后再开平方，称为均方根误差（root mean squared error，RMSE）。

这里正式介绍一下这两种评价指标的数学定义。假设一共有 n 个检查样本，y_i 是第 i 个样本的实际值，$\hat{y}_i$ 是其预测值，i 表示样本在本次计算中的序号。符号 $\sum_{i=1}^{n}$ 表示把第 1 个到第 n 个样本的相应项相加。于是：

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|\hat{y}_i - y_i|.$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2}.$$

两个指标基于同一组预测与实际值，但汇总方式不同。RMSE 先平方，使较大的误差在平均中产生更大影响；最后开平方，使结果重新回到原目标的单位。因此相比于 MAE，RMSE 对较大偏差更敏感。形象地说，在总样本数相同且其余样本误差为 0 时，对于 MAE 而言，一次偏差 10 和十次偏差 1 没有区别，但对 RMSE 来说，前者远差于后者。

4.2 从逐行误差完成一次计算

下面四个批次是独立的手算示例，能耗单位为 kWh。

样本	实际能耗	预测能耗	预测减实际	绝对误差	平方误差
1	10	10	0	0	0
2	20	18	−2	2	4
3	30	32	2	2	4
4	40	36	−4	4	16

绝对误差总和为 $0+2+2+4=8$，共有 4 个样本，所以：

$$\mathrm{MAE}=\frac{8}{4}=2\ \mathrm{kWh}.$$

平方误差总和为 $0+4+4+16=24$，先除以 4，得到平均平方误差 6，再开平方：

$$\mathrm{RMSE}=\sqrt{\frac{24}{4}}=\sqrt{6}\approx 2.45\ \mathrm{kWh}.$$

平方过程中，各项单位为 kWh^2，最后开平方，单位恢复为 kWh。与 MAE 类似，RMSE 也不是总耗电量，而是预测误差的汇总。此外，要注意计算时不能先对每行平方误差开方、再求平均。那样得到的将不再是 RMSE，而是 MAE。

4.3 指标选择影响如何比较误差

正如 4.1 所说，相比于 MAE，RMSE 对较大偏差更敏感，这意味着少量异常记录可能明显影响 RMSE。因此，如果任务特别关心较大的预测偏差，RMSE 可以提供与 MAE 不同的观察。但是这并不意味着 RMSE 优于或劣于 MAE，实际解释结果时需要结合记录情况完成。

比较方法时应沿同一指标：模型 A 的 MAE 应与模型 B 的 MAE 比较，模型 A 的 RMSE 应与模型 B 的 RMSE 比较。不能将模型 A 的 MAE 与模型 B 的 RMSE 进行比较。另外，数学上任意一组误差的 RMSE 总是不小于其 MAE。这是定义带来的性质，不能据此判断模型或指标的优劣。

5. 从分类结果看清正确、漏报与误报

5.1 先确定正类，再组织混淆矩阵

分类任务需要按类别判断及错误类型评价。当我们重点评价某一类别的识别情况时，可以把该类别称为正类，把其余类别合并视为负类。在 T01 的情境中，我们关心能否识别能耗超限批次，因此超限批次被视为正类，非超限批次则统称负类。T01 只有超限和正常两类批次，所以负类就是正常批次；若还有其他类别，负类则包括所有非超限类别。评价另一个类别时，也可以重新指定正类。正和负只是当前评价的角色，不表示好与坏。

每个批次都有实际类别和预测类别，两个类别组合成四种情况：实际超限且预测超限，实际超限却预测正常，实际正常却预测超限，以及实际正常且预测正常。把这四种情况计数并排列起来，就得到混淆矩阵。下面约定行表示实际类别，列表示预测类别；其他材料可能采用不同方向，阅读时要先看行列标题。

实际类别 / 预测类别	预测超限	预测正常	行合计
实际超限	8	2	10
实际正常	12	78	90
列合计	20	80	100

实际超限并被识别的 8 个批次称为真正例，记为 TP (true positive)；漏掉的 2 个超限批次称为假负例，记为 FN (false negative)；误报为超限的 12 个正常批次称为假正例，记为 FP (false positive)；

正确判断正常的 78 个批次称为真负例，记为 TN (true negative)。注意这里“真 / 假”表示判断是否正确，“正 / 负”表示预测类别。TP 和 TN 是正确判断，FP 是误报，FN 是漏报。

5.2 准确率（Accuracy）：全部样本中判断正确的比例

准确率衡量的是全部样本中判断正确的比例，因此其分母是全部检查样本数，分子是其中判断正确的样本数。在本例的二分类矩阵中，因为“真 / 假”表示判断是否正确，所以分子包括真正例 8 个、真负例 78 个，合计 86 个，因此：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}} = \frac{8 + 78}{100} = 86\%.$$

若同一批样本全部预测为正常，则 90 个正常批次都判断正确，10 个超限全部漏掉，准确率为 90%。候选模型的 86% 准确率低于这个多数类基线，但候选识别出 8 个超限批次，基线一个也没有识别。可以看到准确率的数值没有说明哪种方法更能帮助发现超限，因为准确率汇总全部样本的正确判断，没有单独考虑某个类别。

5.3 精确率（Precision）：被判断为某一类别的样本中判断正确的比例

精确率关注的是被判断为某一类别的样本中判断正确的比例。例如，在被预测为超限的批次中，有多少真的是超限批次。因此分母是被判断为正例的总样本数（TP + FP），分子是正确被识别为正例的样本数（TP）。本例预测超限 20 个，其中 8 个真的超限、12 个属于误报，所以：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{8}{8 + 12} = 40\%.$$

40% 意味着本例每 20 次超限判断中有 8 次对应真实超限，不能理解成模型识别了 40% 的实际超限。如果每次超限判断都需要人工复核，12 次误报就会消耗额外检查资源。精确率可以帮助讨论这些判断是否足够可靠，但它本身没有说明模型还漏掉了多少真实超限。

5.4 召回率（Recall）：确实为某一类别的样本中被正确判断的比例

召回率关注的则是确实为某一类别的样本中被正确判断的比例。例如，在实际超限的批次中，有多少被正确识别出来。因此分母是全部真实标签为正例的样本总数（TP + FN），分子同样是正确被识别为正例的样本数（TP）。本例共有 10 个真实超限，识别 8 个、漏掉 2 个，因此：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{8}{8 + 2} = 80\%.$$

80% 表示 10 个实际超限批次中有 8 个被识别；40% 表示 20 个超限预测中有 8 个判断正确。两个指标的分母不同，因此可以同时成立：模型找出了大部分真实超限，但发出的超限判断中也包含较多误报。对同一个模型，改变判定条件可能同时影响漏报与误报。具体怎样调整，将在后续分类模型中讨论。

如果漏报后果严重，就重点关注召回率。但这不意味着可以放弃精确率。把全部 100 个批次都预测为超限，召回率会达到 100%，但代价是误报全部 90 个正常批次，精确率只有 10%。实际任务中，需要把漏报后果、误报成本和可用复核资源一起考虑。

5.5 指标的分母对应不同问题

指标	分母中的对象	回答的问题	结果
准确率	全部检查批次	全部批次中判对多少?	86%
精确率	预测为超限的批次	发出的超限判断有多少是真的?	40%
召回率	实际超限的批次	真实超限中识别出多少?	80%

列举和解释分类任务的指标时要说明正类和分母，不能只写“准确程度”。本例的精确率与召回率分母均非零；实际程序还要约定分母为零时怎样处理和解释，但这不改变三种指标各自关注的问题。

6. 在同一评价安排下选择候选

6.1 训练分数与验证分数一起看

现在看一张用于理解选择依据的假设结果表，单位为 kWh。三个方法使用相同的训练集、验证集和评价指标。

方法	训练 MAE	验证 MAE
简单基线	60	65
候选 A	12	15
候选 B	0	40

候选 B 在训练集上误差为 0，但在验证集上误差为 40；候选 A 的训练误差为 12，验证为 15。如果事先决定以验证 MAE 为标准做选择，两个候选模型中应该选择 A，它的验证 MAE 也优于基线的 65。候选 B 在训练集上的指标较优，但候选 A 在未参与训练的验证集上误差更小。

候选 B 的训练表现非常好、验证表现却明显较差，提示模型可能过度适应训练数据，未能把相应关系有效用于新记录，这种现象正是在 1.1 中提到的过拟合。不过虽然数据提示需要检查过拟合，但仅凭这张表还不能确定差距的原因。划分差异、数据质量和生产条件变化可能会导致训练集与验证集之间的系统性差距，从而影响评价指标。

训练误差与验证误差之间也不存在“训练误差必须更小”的绝对规则。误差会随着样本变化，可能恰好出现验证记录更容易预测的情况。若出现验证误差略低于训练误差，不应仅据此判定程序错误，而应检查划分、训练范围和指标的对应关系。

6.2 先明确比较，再限制结论

为了判断改善是否来自模型，两个模型在比较时应使用相同的训练集、验证集、输入可用条件和评价指标。如果其中一个模型改用了另一组更容易的验证样本，指标的差距便不再是在相同条件下得到的证据。回归和分类任务在比较时，都应保留完整的比较条件，而不是只报告一个孤立分数。

在上述安排下，可以说“候选 A 在本次验证集上的 MAE 为 15 kWh，低于候选 B 和基线”。这为选择候选 A 提供了数据证据。但要注意的是，这既不能说明候选 A 在所有条件下都是更好的模型，也不能说明差异已经经过了统计检验。如果没有独立测试，就不把验证成绩声明为最终测试表现。

评价结果同时是选择依据和继续研究的起点。如果想要改进候选 A，可以用训练与验证范围内的数据继续检查问题；随着这些结果参与调整，若还需要独立最终结论，就仍需另留测试数据。比较数值与说明数据用途，是同一个评价过程的两部分。

7. 本章小结：先安排证据，再解释分数

T01 把任务、数据、规则、预测与评价连在一起；本章进一步区分数据在评价流程中的不同用途。训练集用来训练模型，验证集用来比较与选择，测试集在方案确定后提供独立最终检查。划分方式要对应新批次、新设备或未来月份等使用情境，数据彼此分开只是起点，还需要检查对象关联与信息时点。

不同评价指标有不同的关注点。回归任务中，MAE 汇总平均绝对误差，RMSE 则通过平方突出较大的误差；分类任务中，准确率衡量整体判断，精确率看正类预测的可靠性，召回率看真实正类的识别情况。具体应用中应结合任务关心的实际内容选择指标，而不是追求数字看起来更好。

实验 B01 将把划分、训练、预测和评价串成一个可运行流程。本章先理解模型接受什么数据、其结果应怎样检查；T03 再解释线性模型怎样根据计划产量进行能耗预测。

8. B01：把训练与验证流程落实到程序

8.1 输入、标签和编号一起组织

B01 的数据说明与完整合成表提供 120 个批次，每个批次有编号、计划产量、总能耗和最终电费。它不是 T01 六行算例的扩展，也不要求先处理 D01 的缺失记录。本次数据完整，唯一预测输入仍是开工前已确定的计划产量。

`X` 收集 120 个批次的计划产量，形状为 `(120, 1)`：120 表示样本数，1 表示每个样本只有一个输入特征。`y` 收集对应的 120 个能耗值，形状为 `(120,)`，表示这些值沿一个维度排列。编号数组 `ids` 同样包含 120 个元素，用于追踪每条记录，不进入模型。

在 pandas 中，用列名列表选择计划产量，会保留表格的二维结构；用单个列名选择能耗，得到一维序列。调用 `.to_numpy()` 转换为 NumPy 数组后，两者分别保留上述形状。

划分时不能分别打乱输入和标签。原来某一行的产量、能耗和编号应一起移动，否则模型可能把一个批次的产量与另一个批次的能耗当作配对数据，指标也会核对错对象。B01 因此将 `X`、`y`、`ids` 一起交给划分函数。

8.2 理解划分函数的参数与返回顺序

`train_test_split` 是 scikit-learn 提供的划分函数。传入几个长度相同的数组，它会用同一分配保留数组间的对应关系；每个输入数组各返回两部分，顺序为该数组的训练部分、保留部分。以两个数组为例，输入是 `X` 与 `y`，返回顺序是 `X_train`、`X_val`、`y_train`、`y_val`，不是先返回所有训练数组、再返回所有验证数组。

下面用六个独立编号和示例数值看这个顺序。它不是 B01 的数据，也不训练模型：

```
import numpy as np
from sklearn.model_selection import train_test_split


example_ids = np.array(["R1", "R2", "R3", "R4", "R5", "R6"])
example_values = np.array([10, 20, 30, 40, 50, 60])
ids_train, ids_val, values_train, values_val = train_test_split(
    example_ids, example_values, test_size=1/3, random_state=42
)
print(list(zip(ids_train.tolist(), values_train.tolist())))
print(list(zip(ids_val.tolist(), values_val.tolist())))
```

在课程环境中运行，输出类似于：

```
[('R6', 60), ('R3', 30), ('R5', 50), ('R4', 40)]
[('R1', 10), ('R2', 20)]
```

具体顺序可能随 scikit-learn 版本略有不同，但训练/验证的对应关系和数量不变。

训练部分含 4 条记录，验证部分含 2 条。例如，R6 移到了训练部分的第一项，但仍与数值 60 配对；R1 进入验证部分，仍与 10 配对。`.tolist()` 将数组转换为普通 Python 列表，便于显示；`zip` 将两个列表的对应元素配成一对，使我们可以直接观察关系是否保留。

回到 B01，传入的是 `X`、`y`、`ids` 三个数组，因此会返回六个数组；每个输入数组的训练部分与验证部分依次排列。

`test_size=1/3` 指保留部分占三分之一，`random_state=42` 固定本次随机分配。虽然函数名和参数名包含 test，本实验把保留部分用于验证比较，所以变量命名为 `val`；库接口的名字不会决定数据实际承担测试还是验证用途。

执行 B01 划分后，应得到 `X_train.shape=(80, 1)`、`X_val.shape=(40, 1)`，两个标签数组分别有 80 和 40 个元素。训练与验证编号无交集，并且合起来覆盖原 120 个编号。Notebook 还按编号回原表核对数值，所以不仅检查形状，也检查每行的产量与标签是否配对。

8.3 读懂 fit、predict 和指标函数

scikit-learn 中的许多模型都采用相近接口。先创建一个模型对象，再调用它的方法；这里“对象”是 Python 中保存模型状态并提供相关操作的程序对象，与前面所说的生产批次对象是不同层

面的用法。方法调用只需按当前流程理解。

`model.fit(X_train, y_train)` 让模型根据训练输入和标签确定预测规则。本次实验中，每个模型只在训练集上拟合一次。随后用这个已经训练好的模型，分别调用 `model.predict(X_train)` 和 `model.predict(X_val)`，得到训练部分和验证部分的预测。计算验证表现时，不重新调用 `fit`。

`predict` 只接收输入，不接收待预测记录的标签。随后，指标函数才把预测与相应的真实标签比较：训练预测对应 `y_train`，验证预测对应 `y_val`。训练指标描述模型对已参与学习记录的表现，不应把它当作新数据证据。

本实验的 `DummyRegressor(strategy="mean")` 对应 T01 的均值基线，它在 `fit` 时取得训练标签的均值，之后对不同输入都返回这个常数。`LinearRegression()` 是本次给定的线性候选工具，会利用计划产量形成预测；它的预测式和参数含义将在 T03 展开。这里使用工具接口，不要求先推导它怎样求得参数，也不增加其他候选或调参。

MAE 使用 `mean_absolute_error(实际值数组, 预测值数组)`。RMSE 在当前 Notebook 中分两步实现：`mean_squared_error(实际值数组, 预测值数组)` 返回平均平方误差，再用 `np.sqrt(...)` 开平方。不要先平均差值再取绝对值，也不要先开方再平均，前者会得到“平均误差的绝对值”，后者会退化成 MAE，都不是 RMSE。每种方法分别记录训练、验证两行结果，两种方法共四行。每行保留方法名、数据部分、MAE 和 RMSE。

模型的`.score()` 方法会按模型接口采用默认评分，并不自动等于本次要求的 MAE 或 RMSE。本实验明确调用两项指标函数，才能让结果名称、单位和实际计算对应起来。

8.4 辅修版任务与核验

辅修 B01 Notebook 已经提供读取数据、组织 `X/y/ids`、结果表外层结构、绘图和检查。你需要补全三个环节：将 `X`、`y`、`ids` 一起划分，训练两种模型，以及计算汇总函数中的两项指标。结果表应由实际预测计算得到。

三项短答依次说明基线均值来自哪部分数据、哪种方法的验证 MAE 较小，以及为什么训练与验证结果都不是独立最终测试表现。比较时引用自己实际运行的数值。实验不需要 D01 的文件，也不另做分类上机；分类指标通过本章纸笔活动理解。

8.5 保留结果与解释

开始前，按课程要求将整个单元复制到可保存的个人目录，保留 Notebook 与数据目录的相对位置。带有 `NotImplementedError` 的代码格是待完成位置；补全相应代码并删除停止提示后，再继续运行。

Notebook 的检查会核对编号对应、80/40 划分、基线预测是否等于训练均值，以及结果表中的数值是否对应实际预测。断言通过说明这些受检条件满足，不代替本人解释为什么按这个流程处理数据。出现错误时，先检查输入与标签、划分返回顺序、`fit` 的数据范围和指标对应对象，再修改重跑。

在自己的 Notebook 副本中保留结果表、图和短答。完成后重启课程内核并运行全部单元格，确认结果能从头重建，再保存文件，按教师指定渠道提交并保留可取回副本；原始 CSV 不覆盖，不另交长报告。理论课的纸笔活动可以穿插进行，用于理解与复习，不必等到读完本章再开始。

9. 自查与迁移

请先独立判断和计算，再核对答案。以下数值与正文计算表不同，用于检查能否迁移方法。

1. 两个候选都只用训练集拟合，但教师根据它们在同一组保留数据上的误差选出一个。保留数据承担什么角色？为什么不能只因“没有参加 fit”就把它称为独立最终测试？

2. 希望在病人就诊开始时预测本次就诊时长，并检查模型对未见过的新病人是否有效。历史数据中，一名病人可能有多次就诊记录。随机把每次就诊记录分到训练集与验证集，为什么可能没有检验对新病人的预测能力？应怎样划分？

3. 三个新批次实际能耗为 12、20、28 kWh，事先预测为 10、20、24 kWh。计算 MAE、RMSE，并说明二者单位。若另一方法只报告训练 MAE，能否据此判断它在这些新批次上更好？

4. 把需要复核的缺陷产品设为正类。60 件产品中实际有 12 件缺陷，模型识别出 9 件，同时把 6 件正常产品误报为缺陷。写出 TP、FN、FP、TN，并计算准确率、精确率、召回率。只看准确率能否解释它是否满足复核需求？

5. 一个实验按事先指定的随机种子得到训练 80 条、验证 40 条。某同学对验证误差不满意，于是尝试 20 个不同的随机种子，只报告其中最低的验证误差。这个数值与按事先指定种子得到的评价结果，含义有什么不同？

6. 新记录按月份持续增加。模型已经在保留月份上做过最终检查；随后你根据这些误差修改了模型。修改是被禁止的吗？怎样才能取得有关新版模型的独立检查证据？

答案要点与回看位置

1. 这批数据承担验证角色，因为结果参与了选择。没有用于训练，只能说明未参加该次参数拟合，不能说明没有影响整个方案的形成。独立测试还要求不参与这次选择。回看 2.2—2.3 节。

2. 同一病人的多次记录可能同时出现在两边，模型已接触该病人的特点，评价未必对应新病人。若目标是预测未见过的病人，应按病人分组，使同一病人的记录留在同一部分，同时检查字段时点。回看 3.2 节。

3. 绝对误差为 2、0、4，MAE 为 $(2+0+4)/3 = 2$ kWh；平方误差为 4、0、16，RMSE 为 $\sqrt{20/3} \approx 2.58$ kWh。另一个方法的训练 MAE 既对应不同对象，也对应不同用途，应让两种方法在同一组新批次上按相同指标比较。回看 4.1—4.3 及 6.2 节。

4. TP 为 9，FN 为 3，FP 为 6，TN 为 42。准确率为 $(9+42)/60 = 85\%$，精确率为 $9/(9+6) = 60\%$，召回率为 $9/(9+3) = 75\%$。这些数值分别说明全部判断、复核判断的可靠性和实际缺陷识别情况；还要联系漏报后果及误报造成的复核负担，不能只看 85%。回看 5.1—5.5 节。

5. 分数已经根据 20 次划分的结果被挑选，除了方法表现，还受所选检查条件影响。固定种子用于复现事先确定的划分，不用于寻找满意分数；应按预定安排报告结果，而不是只报最有利一次。回看 3.1 及 6.2 节。

6. 可以开发新版模型，但旧保留月份的结果已经参与改进，不再独立于新版方案。需明确新版模型的训练与选择范围，并安排未参与这轮形成与选择、又符合未来预测时点的新保留记录作检查。回看 2.3、3.3 及第 7 节。