T03 线性回归与平方损失

从预测规则到训练目标

机器学习课程学生讲义

辅修版 · 2026 年 10 月 8 日

学生讲义 · 辅修版。对应 T03（2 理论学时）；T04 之后完成 B02。

导读

T01 说明了怎样定义预测任务和建立简单基线，T02 说明了怎样安排训练、验证与测试，以及如何解释评价指标。在 B01 中，我们把计划产量交给了一个线性模型，得到了能耗预测。不过，我们还没有解释训练过程究竟怎样确定模型参数。本章将就此进一步展开。

仍以 T01 中开工前预测批次总能耗的情境为例，均值基线对所有批次的预测是相同的。但是在这个情境中，根据历史批次的信息，我们预期计划产量不同的批次，其总能耗也很可能不同。因此我们希望模型能够利用计划产量的差异给出不同的预测。在所有满足这个条件的模型中，线性模型是结构比较简单的，因此选择线性模型作为起点。对于线性模型，给定直线的位置和倾斜程度，就可以计算预测值；再把预测值与训练标签比较，用一个指标汇总误差，作为训练时比较参数的依据，这个指标称为损失。最后讨论怎样通过调整直线让损失变小。

> 选定线性形式 → 给定参数并计算预测 → 用训练标签计算损失 → 比较不同参数 → 明确训练要寻找什么。

本章回答 “模型是什么、怎样衡量拟合、训练目标是什么”。T04 继续回答 “怎样利用损失的变化方向更新参数”。理论课通过读图和纸笔计算理解过程；第 7 节提供实验查阅支持，代码不要求在理论课现场运行。阅读后应能写出一元线性预测式、解释参数、计算平方损失，并区分训练目标和验证证据。

1. 用一条直线表达随输入变化的预测

1.1 从均值基线到线性模型

回顾 T01 中的情境：我们需要在一个生产批次开工前，根据当时已确定的计划产量预测完工后的总能耗。对单个批次，用 x 表示计划产量，y 表示实际能耗，$\hat{y}$ 表示预测能耗。

均值基线只读取训练标签，计算一个常数，以后每个批次都输出该常数。它是一个合适的基线，但没有利用当前批次的产量信息。为了让预测利用产量的信息，一个简单的候选模型是：

$$\hat{y} = wx + b.$$

其中 w 称为斜率，控制输入改变时预测改变多少；b 称为截距，控制整条直线的上下位置。例如，取 $w = 2, b = 40$，计划产量为 30 时，预测为 $2 \times 30 + 40 = 100$；产量为 50 时，预测为 140。这里两个批次使用同一组 w, b，预测的差异来自输入不同。

x, y 是数据中的特征和标签，w, b 是模型参数。训练是利用历史记录确定参数，预测则是把新批次的输入代入参数已经确定的模型，得到输出。只给出直线形式，还不能计算具体预测值，给定参数后，就可以计算预测，但这组参数是否适合当前任务，还需要通过数据判断。

1.2 斜率、截距和预测的含义

参数 w, b 如何影响线性模型的预测？先保持 w 和 b 不变，将输入从 x 增加到 $x + \Delta x$，预测的变化为：

$$[w(x + \Delta x) + b] - (wx + b) = w\Delta x.$$

因此，当输入增加一个单位时，预测增加 w 个目标单位。如果 w 为负，预测就会下降。

另一方面，保持 w 不变而将 b 增加 10，每个输入的预测都会增加 10。

参数的单位也由预测式决定。b 与能耗具有相同单位；w 的单位是“能耗单位 / 产量单位”。如果改变输入的计量单位，表达同一组预测所需的 w 数值也会随之改变，不能脱离单位比较斜率大小。

截距是在 $x = 0$ 处的模型预测。如果训练记录中的产量全部位于 20—100 范围内，就不能直接把 b 解释为工厂真实的固定能耗，因为数据并没有检验零产量的情形。同样，斜率只表达模型中输入与预测的变化关系，仅凭这种拟合关系，还不能证明改变产量会造成同样的能耗变化。

1.3 均值基线与线性模型的关系

将 w 设为 0，线性模型将退化为 $\hat{y} = b$，预测不再随输入变化。如果再把 b 确定为训练标签的均值（记为 $\bar{y}_{\text{train}}$），就得到了在 T01、T02 使用的均值基线。图形上，这是一条水平线。

我们希望回答的问题是，在相同数据划分、评价指标和预测时点下，允许预测随产量变化，是否比始终输出一个常数更有效？线性模型提供了一个允许预测随产量变化的方案，但预测效果是否真的改善，需要看训练得到的参数及其在验证集上的表现。

2. 为每个样本计算预测，再与标签对应

2.1 一个模型对所有样本使用同一组参数

一份数据中有多个批次，对于第 i 个批次，x_i 和 y_i 分别表示该批次的输入和标签。据此，单样本预测式可以写成：

$$\hat{y}_i = wx_i + b.$$

其中下标 i 用于区分样本，参数 w, b 没有下标，因为预测时同一个模型对所有样本使用同一组参数。训练时，我们希望找到一组能够同时拟合这些训练记录的参数，而不是为每一条训练记录单独确定一组参数。后一种做法没有建立面对新输入时统一使用的预测规则。

2.2 用训练标签比较不同参数

给定一组参数 w, b，就能根据各个样本的输入计算预测值。训练记录还提供对应的真实标签，因此可以把预测与标签逐一比较，检查这组参数拟合得怎样。换一组参数，预测值及其与标签的差距也会随之改变。训练标签由此为选择参数提供了依据。

但一组参数可能在某些样本上预测得更准，在另一些样本上误差更大。要比较两组参数，不能只挑其中一个样本，而要用相同的计算方式，把全部训练样本上的误差汇总起来，作为选择参数的依据。接下来，我们从单个样本的误差出发，建立这样的汇总方法。

3. 用平方损失汇总预测误差

3.1 保留方向与衡量大小是两个问题

本课程把预测值与实际值的差称为残差，统一记为：

$$e_i = \hat{y}_i - y_i,$$

在本章的线性模型中，

$$e_i = \hat{y}_i - y_i = wx_i + b - y_i.$$

正残差表示预测偏高，负残差表示预测偏低。本课程统一采用预测减实际，后续的计算也会沿用这个定义。有些参考材料也可能采用相反方向，读者阅读时应先确认。

残差的方向有助于判断高估或低估，但残差的平均值不能充分反映误差大小，因为高估和低估会互相抵消。例如两个残差为 -3 和 3，平均是 0，却没有一个预测正确。T02 介绍了绝对值和平方两种汇总方式来解决这个问题，本章选择平方来汇总误差。

3.2 均方误差（MSE）与半均方误差

设当前参与计算的样本共有 n 个，先把每个残差平方，再取平均，得到均方误差：

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n} e_i^2.$$

平方将正负残差都转换为非负数，避免抵消，也使较大的误差在汇总中占更大比重。取平均则让数值描述每个样本的平均平方误差。如果只是把相同样本重复一遍，平均值不变。对新样本或不同分布，平均误差仍可能改变。

为了简化后续章节的数学计算，本章将 MSE 再除以 2，定义：

$$J(w,b)=\frac{1}{2n}\sum_{i=1}^{n}(wx_i+b-y_i)^2=\frac{1}{2n}\sum_{i=1}^{n}e_i^2.$$

$J(w,b)$ 是均方误差的一半，即半均方误差。它可以用来表示给定参数时的误差汇总，称为损失。损失在这里是用来衡量预测与训练标签吻合程度的数值，较小意味着在这些样本上平方误差较小。

乘以正的常数 1/2 不会改变使损失最小的参数，因为任意两组参数的损失大小关系不变。本章保留这个系数，是为了简化后续章节的数学计算。不过，MSE 与半均方误差的具体数值不同，后续计算以及核对时应确认使用的是哪一个指标。

3.3 损失与评价指标的联系

回顾 T02 中的 RMSE，它就是在均方误差的基础上再开平方，使指标的单位与标签一致。因此，在同一组样本、同一组预测上：

$$\mathrm{RMSE}=\sqrt{\mathrm{MSE}}=\sqrt{2J}.$$

若标签用能耗单位表示，J 的单位是能耗单位的平方，RMSE 仍是能耗单位。前者便于表达本单元的训练目标，后者便于解释预测误差的尺度。此外，在同一组样本上比较不同参数得到的预测时，较低的 J 等价于较低的 RMSE，因为平方根函数是单调递增函数。

但注意不能用训练 J 直接代表验证 RMSE。两者必须各自在对应样本上计算。训练要降低训练损失，而比较模型是否适合新对象，仍需按 T02 的安排检查验证表现。平方损失还会明显受到极端误差影响，选择它并不意味着它适用于所有任务。

4. 从输入到损失：一个算例

4.1 固定参数，逐行计算

先暂时离开完整批次数据，用一份包含三个样本的小型生成数据集来观察一下实际机制：

$$x=[0,1,2],\qquad y=[1,3,5].$$

这里 x,y 分别表示三条输入和标签的序列；x_i,y_i 表示其中第 i 条记录的输入和标签。

先取 $w=1,b=0$，此时每个预测都是 $\hat{y}_i=x_i$：

x_i	y_i	$\hat{y}_i$	$e_i=\hat{y}_i-y_i$	e_i^2
0	1	0	−1	1
1	3	1	−2	4
2	5	2	−3	9

三个残差的平方和为 14，样本数为 3，所以：

$$J(1,0)=\frac{1+4+9}{2\times 3}=\frac{7}{3},\qquad \mathrm{RMSE}=\sqrt{\frac{14}{3}}\approx 2.16.$$

从输入到预测、从预测到残差、从残差到损失，每一步都保留了样本对应关系。损失把这些逐行差异汇总成一个数值，但如果想要探究误差具体来自哪里，还需要回到逐行差异。

4.2 改变参数，检查损失怎样变化

保持 $w=1$，将 b 从 0 改为 1，会使每一个预测都增加 1，得到 $\hat{y}=[1,2,3]$。残差变成 $[0,-1,-2]$，平方和为 5，于是 $J(1,1)=5/6$，低于原来的 $7/3$。

再取 $w=2,b=1$，三个预测为 $[1,3,5]$，正好与标签一致，损失为 0。这说明参数会改变预测和损失，当前三个点又恰好位于一条直线上。实际标签可能带有噪声，单一特征也可能不足以解释全部变化，不能根据这个例子推断所有数据都可以达到零损失。

改变截距与改变斜率，对各个样本预测值的影响方式不同。改变截距时，每个预测移动相同数值；改变斜率时，移动量取决于输入。例如 $x=0$ 处的预测不受斜率改变影响，而 $x=2$ 处会产生相应变化。这一关系将帮助 T04 解释为什么两个参数具有不同的调整依据。

5. 训练是在固定数据上寻找更好的参数

5.1 模型形式、参数和训练目标

选择线性模型 $wx+b$ 确定了允许使用的模型形式，计算 J 确定了比较参数的标准。训练的本质是把这两者连接起来：在模型形式、训练数据和损失定义固定的条件下，寻找使损失较小的 w,b。

可以把这一目标写为：

$$\min_{w,b} J_{\mathrm{train}}(w,b).$$

$\min_{w,b}$ 读作 “对 w,b 求最小值”，意思是在 w 和 b 允许的范围内寻找训练损失 J_{train} 的最小值。下标 train 提醒我们，这里参与目标计算的是训练样本。

想象把 w,b 作为平面上的两个坐标，每一对坐标都对应一个损失值。寻找参数，就是比较不同位置上的损失。在训练数据和损失定义保持不变的条件下，损失下降表示模型在这些训练样本上的平方误差减小，但不保证它在新样本上也表现更好。

5.2 最小化的简单尝试及其局限

最直接的探索是固定一个参数，只改变另一个。例如，对第 4 节的小数据集保持 $w=1$，尝试 $b=0,1,2,3$：

b	预测	残差	$J(1,b)$
0	$[0,1,2]$	$[-1,-2,-3]$	$7/3$
1	$[1,2,3]$	$[0,-1,-2]$	$5/6$
2	$[2,3,4]$	$[1,0,-1]$	$1/3$
3	$[3,4,5]$	$[2,1,0]$	$5/6$

这几个结果中，$b=2$ 的损失最小。但它只是 $w=1$ 且 $b=0,1,2,3$ 时的最好结果。我们已经知道 $w=2,b=1$ 能得到零损失，因此不能把这次一维试探结果说成所有参数中的最优。

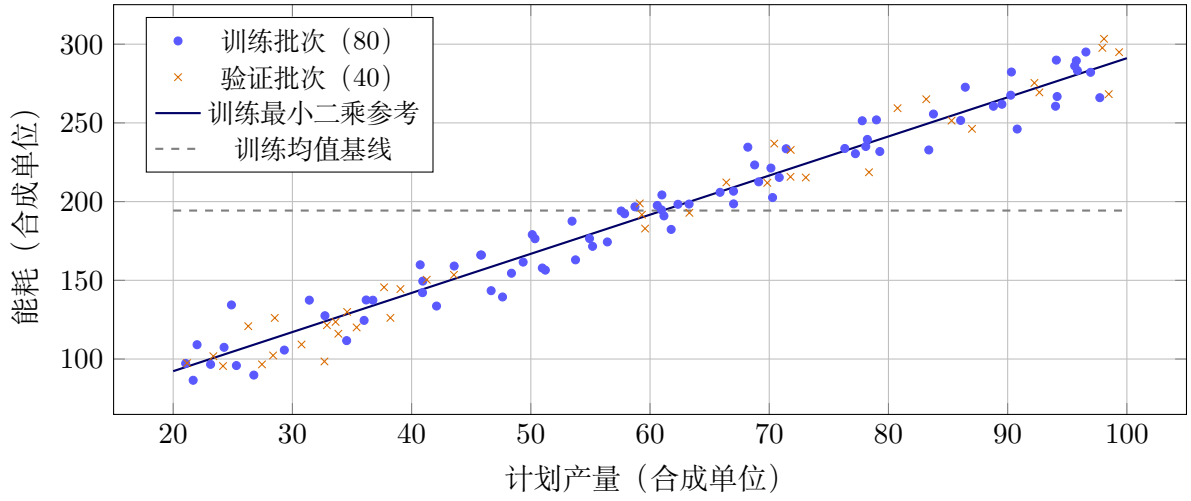
这种探索帮助观察参数作用，却没有告诉我们下一次应尝试哪个数。若参数更多或取值范围更大，逐个枚举的成本会迅速增加，因此需要更有效的参数调整方法。T04 将利用当前位置附近的损失变化，决定参数应往哪一方向调整。

5.3 最小二乘参考与验证检查

通过选择模型参数，使训练样本的残差平方和最小的拟合方法，称为最小二乘法。本章用它来拟合一元线性模型。对于固定训练样本，最小化残差平方和、均方误差或半均方误差，会得到相同的最优参数集合，因为这些目标函数只相差一个正的常数因子。

B01 中使用的 `LinearRegression` 可以直接提供最小二乘法的拟合结果，作为本单元比较的参考。它不需要采用 T04 将展示的手写逐步更新循环。我们使用它核对参数试探或更新后得到的训练损失，是否接近同一训练目标的最优值，不展开其数值求解算法。

下图使用 T03—T04 单元另行生成的 120 个合成批次，与 B01 的数据不同，但沿用相同的预测任务和训练 / 验证分工。其中预先固定 80 个批次用于训练、40 个用于验证，没有独立最终测试集。计划产量在开工前已确定，能耗在完工后取得；编号与划分标记只用于关联记录和区分用途，不作为输入。



图中圆点表示训练批次，叉号表示验证批次；水平虚线是训练标签均值，实线是只用训练数据得到的最小二乘参考。斜线利用产量变化产生不同预测，而水平线输出同一个常数。是否改善对新批次的预测效果，应在相同验证对象上按同一指标比较，不能仅凭图上更贴近训练点作结论。

阅读补充。对本章带截距的一元平方损失，当训练输入至少有两个不同值时，最优参数唯一；若全部输入相同，不同斜率和截距可能给出相同预测，参数就不一定唯一。这些结论只适用于本章的线性模型和平方损失目标，不能直接推及后续模型。

6. 本章小结：训练是在做什么

一元线性模型用 $\hat{y} = wx + b$ 的形式将输入变成预测，同一个模型对各个样本共用参数。斜率改变输入与预测之间的变化关系，截距把整条直线上下移动。给定训练标签以后，可以逐行计算残差，再用半均方误差汇总参数当前的拟合程度。

训练的目标是在固定训练数据上，寻找使损失较小的参数。有限试探能帮助观察，但试过几个值并不保证找到所有参数中的最优。最小二乘参考提供同一平方损失目标下的比较依据，验证集则检查形成的规则对未参与拟合的样本表现怎样。在训练集上把损失降到较低，与在验证集上取得较小的预测误差，是两个不同的问题。

7. 纸笔活动

配套的纸笔活动包含 T03、T04 两部分。本章使用 T03 部分的 A1—A4：先按样本计算预测与残差，再汇总损失、比较参数，检查输入与标签的对应关系，最后说明训练结果能够支持什么结论。第 4 节提供了逐行计算的依据，第 5 节解释怎样理解参数比较。活动可以穿插在相应内容之后完成。

梯度、更新和尺度部分的活动，将在学习 T04 后再进行。

8. 自查与迁移

先独立作答，再核对解析。计算可以保留分数或根号。

1. 均值基线怎样写成 $wx + b$？它已经有参数，为什么仍被称为基线？
2. 若 $w = 2, b = 40$，输入从 30 增至 35，预测增加多少？截距一定是工厂真实固定能耗吗？
3. 对 $x = [1, 2, 4], y = [3, 5, 9]$，取 $w = 2, b = 0$，写出预测、残差、J 及 RMSE。若只把 b 改为 1，结果怎样变化？
4. 两个残差为 $-2, 2$。平均残差、MSE、半均方误差和 RMSE 分别是多少？这个例子说明了什么？
5. 对第 5.2 节样本，固定 $w = 1$ 时，试到的最好截距是 $b = 2$。为什么不能据此宣布已找到这份数据的最优线性模型？
6. 模型在训练样本上达到零损失，能否据此宣布未来批次预测完全正确？应取得什么证据？
7. 如果把输入与标签分别重新排序，再按位置计算残差和损失，得到的结果是否一定还是原来那些样本的损失？为什么？

8. 在同一批训练样本上，以 MSE 或半均方误差为训练目标，最优参数是否相同？对同一组预测，两种损失的数值是否相同？为什么？

答案要点与回看位置

1. 取 $w = 0, b = \bar{y}_{\text{train}}$。它由训练标签确定一个常数，提供简单的比较起点；基线可以具有参数并经过训练，不是“没有模型”。回看第 1.3 节。

2. 增加 $2 \times (35 - 30) = 10$ 个能耗单位。b 是模型在零输入处的预测，若没有零产量附近的观测，不能据此认定真实固定能耗；预测拟合也不直接建立因果解释。回看第 1.2 节。

3. 预测 $[2, 4, 8]$，残差 $[-1, -1, -1]$，$J = 3/(2 \times 3) = 1/2$，RMSE 为 1。改为 $b = 1$ 时，预测 $[3, 5, 9]$，残差全为 0，J 与 RMSE 均为 0。这个小表恰好能被直线拟合，结论限定于这三个点。回看第 3.2、4.1—4.2 节。

4. 平均残差为 0，MSE 为 4，$J = 2$，RMSE 为 2。正负残差可以互相抵消，因此平均残差为零不表示预测准确。取绝对值或平方后再汇总，可以避免这种抵消；RMSE 仍满足 $\sqrt{2J}$。回看第 3.1—3.3 节。

5. 这里只比较固定斜率时的几个截距，范围没有覆盖其他斜率；$w = 2, b = 1$ 已经能得到更小的零损失。因此结论只能是“在这些固定条件与候选中最好”。回看第 4.2、5.2 节。

6. 不能。训练表现反映对已用于确定参数的记录的拟合，未来数据可能有噪声或条件变化。先在符合任务的未参与训练的验证对象上评价；若还依据结果选模，最终方案另需未参与这轮形成与选择的测试集上的独立检查结果。回看第 3.3、5.3 节及 T02。

7. 不一定。输入与标签必须保持原记录的对应关系；分别排序可能把一个样本的预测与另一个样本的标签配在一起。此时即使计算能完成，也不是原来那些样本的预测误差。若要改变记录顺序，应将每条记录的输入与标签一起移动。回看第 2.1、4.1 节。

8. 对固定样本，$J = \text{MSE}/2$。正比例缩放不改变损失的大小顺序，因此两种目标的最优参数集合相同。对同一组预测，半均方误差是 MSE 的一半，除非误差为零，否则两种损失的数值不同。回看第 3.2、5.3 节。