T04 梯度下降、学习率与尺度

从损失到参数更新

机器学习课程学生讲义

辅修版 · 2026 年 10 月 10 日

学生讲义 · 辅修版。对应 T04（2 理论学时），之后完成 B02（2 实验学时）。

导读

在 T03 中，我们介绍了线性模型，说明了在给定参数的情况下如何计算预测与损失，并明确了训练的目标是在固定的训练数据上寻找损失较小的参数。但是，逐个尝试几组参数值，只能找到这些候选参数组中的最好结果，而逐个枚举参数组通常不可行。本章将从损失在当前位置附近怎样变化出发，建立系统调整参数的方法。

仍以一元线性模型 $\hat{y} = wx + b$ 和半均方误差为例。我们先判断参数略微增大或减小时，损失怎样变化；再选择能够使损失减小的参数调整方向，并控制移动的幅度；最后重新计算损失，检查这一步是否改善了训练拟合。不断重复，就把 T03 中的参数比较变成了一个系统的训练方法。

> 用当前参数计算预测与损失 → 判断损失对参数的变化率 → 确定调整方向和幅度 → 更新参数 → 核对结果并继续。

完成本章后，读者应能通过读图和纸笔计算理解训练过程。具体来说，应能解释偏导与梯度，沿用 T03 的三个样本算出一次同步更新，说明学习率与输入尺度为什么影响训练，并区分训练进展与验证表现。第 8 节提供 B02 的操作查阅支持。本章不展开矩阵求导、复杂优化器或收敛率证明。

1. 用当前位置附近的变化判断方向

1.1 从平均变化率到导数

先看只有一个参数的函数 $f(a) = (a-3)^2$。当 a 从 1 移动到 1.1，函数值由 4 变为 3.61，平均变化率为：

$$\frac{f(1.1) - f(1)}{1.1 - 1} = \frac{3.61 - 4}{0.1} = -3.9.$$

这个负值说明，在这一段移动中，平均而言，参数增大时函数值减小。如果进一步缩小移动范围，平均变化率会接近当前位置的变化率，也就是导数。对示例函数，$f'(a) = 2(a-3)$，所以 $f'(1) = -4$。

导数的符号可以帮助判断调整方向。在 $a=1$ 附近，导数为负，略微增大参数可以降低函数值；在 $a=5$ 附近，导数为正，略微减小参数可以降低函数值。导数的绝对值反映这个位置附近函数值对参数变化的敏感程度。

需要强调“附近”，因为导数描述局部变化。从 $a=1$ 向右移动，开始会靠近最低点 $a=3$，但如果一直移动到 $a=9$，函数值反而升到 36。调整方向和移动幅度需要一起考虑。

1.2 两个参数分别怎样影响损失

T03 中介绍的线性模型的损失函数 $J(w,b)$ 同时依赖两个参数。要观察斜率的影响，可以固定截距 b，只改变 w；要观察截距的影响，可以固定 w，只改变 b。固定其余参数、对一个参数求出的变化率，称为偏导数。

分别记为：

$$\frac{\partial J}{\partial w}, \qquad \frac{\partial J}{\partial b}.$$

符号 ∂ 在这里表示偏导；$\partial J/\partial w$ 读作“J 对 w 的偏导”。两个偏导数描述同一个参数位置上，沿两个坐标方向的局部变化。把它们按参数顺序组织起来，就得到梯度：

$$\nabla J = \left(\frac{\partial J}{\partial w}, \frac{\partial J}{\partial b} \right).$$

∇J 读作“J 的梯度”。梯度的分量对应参数，不对应样本：本章无论有三个还是八十个训练样本，都只有 w, b 两个待调整参数，因此梯度有两个分量。样本的残差则每个样本有一个，两者承担不同工作。

对于任意可微的损失函数，在梯度非零时，沿负梯度移动足够小的一步总是可以降低当前损失。梯度为零则意味着一阶变化率为零；是否已经达到最优，还需要结合函数性质判断。

2. 从预测与残差推导平方损失的梯度

2.1 追踪损失函数怎样随参数变化

沿用 T03 的约定：

$$e_i = wx_i + b - y_i, \qquad J(w,b) = \frac{1}{2n}\sum_{i=1}^{n} e_i^2 = \frac{1}{n}\sum_{i=1}^{n} \frac{e_i^2}{2}.$$

计算损失对参数的变化率时，训练样本 x_i, y_i 保持不变。对单个样本，计算经过两层：参数先改变残差 e_i，残差再改变半平方项 $e_i^2/2$。要得到整条路径的变化率，需要把两层的变化率相乘，这就是链式法则。

先看后一层。$e_i^2/2$ 对 e_i 求导，平方产生系数 2，与前面的 $1/2$ 抵消，结果为 e_i。这解释了 T03 为什么定义 J 为 MSE 的一半。再看前一层，残差对斜率的变化率为 x_i，对截距的变化率为 1。因此：

$$\frac{\partial(e_i^2/2)}{\partial w} = e_i \frac{\partial e_i}{\partial w} = e_i x_i,$$
$$\frac{\partial(e_i^2/2)}{\partial b} = e_i \frac{\partial e_i}{\partial b} = e_i.$$

改变截距，会让所有样本的预测变化相同数值；改变斜率，预测的变化量则与输入有关。因此，斜率对应的式子要乘 x_i，截距对应的式子不需要。这与 T03 对两个参数的解释一致。

2.2 对全部训练样本取平均

半均方误差是各样本半平方误差的平均值，对它求导，也就是把各项的导数取平均。因此：

$$\frac{\partial J}{\partial w} = \frac{1}{n}\sum_{i=1}^{n} e_i x_i, \qquad \frac{\partial J}{\partial b} = \frac{1}{n}\sum_{i=1}^{n} e_i.$$

后文分别用 g_w, g_b 表示这两个偏导数。它们都在当前参数上计算，都是标量。截距梯度是平均残差，但这不意味着平均残差可以衡量总体误差大小：这里用它判断截距的调整方向，损失仍由残差平方汇总。

如果训练目标改为 MSE，去掉前面的系数 $1/2$，两个梯度就会各自变成上述结果的两倍。最优参数不变，梯度数值却改变。因此，实现梯度前要确认它对应哪一种损失。

3. 根据梯度完成一次同步更新

3.1 学习率控制移动幅度

知道了当前梯度，还要决定沿负梯度走多远，决定这一点的是学习率 η。学习率乘到梯度上，决定了移动的幅度。设 $\eta > 0$，则更新规则为：

$$w_{\text{new}} = w_{\text{old}} - \eta g_w, \qquad b_{\text{new}} = b_{\text{old}} - \eta g_b.$$

减号让参数沿负梯度方向移动。若 $g_w < 0$，减去负数就使 w 增大；若 $g_w > 0$，w 则减小。学习率是训练过程的设置，不是预测式中的模型参数。

先计算两个梯度，再计算两个新参数，便完成一次梯度下降更新。两个梯度必须来自同一组旧参数，否则这一步就不再是上述更新规则。

3.2 示例计算

继续使用 T03 的算例 $x = [0, 1, 2]$、$y = [1, 3, 5]$，旧参数为 $w = 1, b = 0$。T03 已算出预测 $[0, 1, 2]$、残差 $[-1, -2, -3]$，旧损失为 $7/3$。计算梯度时，还需要逐行计算残差与输入的乘积：

x_i	y_i	$\hat{y}_i$	e_i	$e_i x_i$
0	1	0	-1	0
1	3	1	-2	-2
2	5	2	-3	-6

所以：

$$g_w = \frac{0-2-6}{3} = -\frac{8}{3}, \qquad g_b = \frac{-1-2-3}{3} = -2.$$

取 $\eta = 0.1$，得到：

$$w_{\text{new}} = 1 - 0.1\left(-\frac{8}{3}\right) = \frac{19}{15}, \qquad b_{\text{new}} = 0 - 0.1(-2) = \frac{1}{5}.$$

再用新参数计算预测和残差：

x_i	新预测	新残差	新残差平方
0	1/5	$-4/5$	16/25
1	22/15	$-23/15$	529/225
2	41/15	$-34/15$	1156/225

新的损失为：

$$J_{\text{new}} = \frac{16/25 + 529/225 + 1156/225}{6} = \frac{1829}{1350} \approx 1.354815.$$

它小于旧损失 $7/3 \approx 2.333333$，说明这一步改善了这些训练样本上的拟合。新参数还不是 T03 已知的零损失参数 $(2, 1)$；一次更新只是训练过程中的一步。

3.3 参数更新的流程总结

一次参数更新的完整顺序是：先用当前参数计算预测、残差与损失，再根据损失函数对参数的依赖关系计算梯度，最后用梯度结合学习率更新参数。两个梯度都应在更新前计算，更新后再重新计算损失，检查这一步的结果。

程序中两行赋值先后执行，并不一定违反同步更新。若 `dw`、`db` 已经从旧参数算好，先赋值给 `w`，再用原先的 `db` 更新 `b`，计算依据仍然一致。但如果在更新 `w` 后又用新参数重算残差与 `db`，两个参数就使用了不同位置的变化率，与本章给出的计算方法不再一致。

4. 学习率决定一步走多远

4.1 方向正确，也可能移动过远

回顾第 1 节的 $f(a) = (a-3)^2$。在 $a = 1$ 处，导数为 -4。若学习率为 0.1，新参数为 $1-0.1(-4) = 1.4$，函数值由 4 降到 2.56。若学习率为 2，新参数为 $1 - 2(-4) = 9$，函数值反而升到 36。

两次参数更新都沿负导数方向，结果却完全不同。较大的学习率导致函数值跨过了低点，并移动到了更高的位置。因此，负梯度提供局部下降方向，学习率则决定了这次移动是否仍处于能改善结果的范围。

当学习率较小时，每一步移动的幅度也较小，可能导致在有限的更新预算内参数优化进展缓慢；当学习率较大时，每一步移动的幅度也较大，可能导致损失函数反复越过低点，造成振荡甚至损失持续增大。因此，训练任务需要合适的学习率。但是另一方面，合适的学习率，需要结合损失函数的定义、数据的尺度和当前训练的过程决定，并不存在一个普适的数字。

4.2 从一次更新到重复训练

梯度下降训练，就是不断重复“计算损失 → 计算梯度 → 更新参数”的过程。本章每次更新过程均使用完整训练集计算梯度，这种训练方式称为全批量梯度下降。除此之外还有一种每次使用一个样本或一小批样本计算损失和梯度更新参数的训练方式，本章暂不展开。

为了比较不同学习率的效果，应让不同的训练过程使用相同数据、相同损失、相同输入处理、相同初始参数和相同更新预算。只有这样，才能把差异主要归因于学习率。若先训练一种学习率，再从其最终参数继续运行另一种，就等于改变了初始状态。

损失曲线异常提示训练过程需要诊断，但仅凭损失曲线自身通常无法确定异常的原因，应结合代码与计算核对更新符号、梯度是否对应实际损失、学习率和输入尺度。学习率太小导致训练不充分与模型本身拟合能力不足也应得到区分；T03 的最小二乘参考可以帮助判断这一点。

5. 输入标准化

5.1 输入尺度改变梯度下降的问题及其解决方案

斜率梯度包含 $e_i x_i$，截距梯度只包含 e_i。输入数值的大小，会影响两个梯度的数值及参数移动对预测的作用。即使只是把同一物理量换成另一种计量单位，输入数值和表达相同预测所需的斜率也会改变，原来的学习率未必仍然合适。

本单元用训练输入的均值与标准差建立新坐标：

$$\mu_{\text{train}} = \frac{1}{n_{\text{train}}} \sum_{i=1}^{n_{\text{train}}} x_i, \qquad \sigma_{\text{train}} = \sqrt{\frac{1}{n_{\text{train}}} \sum_{i=1}^{n_{\text{train}}} (x_i - \mu_{\text{train}})^2},$$

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}.$$

这里 n_{train} 是训练样本数，μ_{train} 表示训练输入的平均值，σ_{train} 表示其标准差。先减去均值，把中心置为零；再除以标准差，使一个标准差的距离对应新坐标中的一个单位，这样的处理称为标准化。若某个特征始终相同，标准差为零，不能直接作除数，应先检查特征。本次只标准化输入，标签仍保留原单位。

标准化后的训练输入均值为 0，平方的平均值为 1。输入以零为中心后，增加斜率会使中心两侧的预测向不同方向变化，而增加截距仍会让所有预测一起上移；除以标准差，则避免输入的数值大

小仅因计量单位不同而相差很大。这使两个参数的调整更容易配合，也使学习率更容易选择。标准化改变的是坐标和优化条件，不会消除标签噪声，也不保证预测能力提高。

本课程计算标准差时分母使用训练样本数，对应 NumPy 的 `std(ddof=0)`。

5.2 验证输入沿用训练变换

模型是在训练坐标中学习参数的，因此训练结束后的输入，包括验证输入或以后的新输入，都应使用训练集的均值和标准差标准化。

例如，训练输入为 $[0, 2]$，验证输入为 $[10]$。训练均值为 1，标准差为 1，所以训练坐标为 $[-1, 1]$，验证坐标为 9。这个 9 表示验证输入距离训练中心有九个训练标准差，不是要求将它也变为接近 0 的数。

如果将验证集用验证集自己的均值和标准差进行标准化，就会导致标准化后的验证集与训练集处于不同的坐标系中。如果合并训练集与验证集计算标准化参数，验证集就参与了训练过程。因此，在本章的训练与验证流程中，应先划分数据，然后仅使用训练集计算标准化参数，并将同一变换用于训练、验证及以后的新输入。

5.3 参数的含义随坐标改变

在标准化坐标中，模型可以写成 $\hat{y} = w_z z + b_z$。下标 z 用来提示参数对应的坐标系。代入标准化公式：

$$\hat{y} = w_z \frac{x - \mu}{\sigma} + b_z = \frac{w_z}{\sigma} x + \left(b_z - \frac{w_z \mu}{\sigma} \right).$$

这里的 μ 和 σ 分别代表训练集的均值与标准差。原始坐标中等价的参数为：

$$w_x = \frac{w_z}{\sigma}, \qquad b_x = b_z - \frac{w_z \mu}{\sigma}.$$

若训练输入的均值为 10、标准差为 2，标准化坐标中的模型为 $\hat{y} = 4z + 7$，则原始坐标中的斜率为 $4/2 = 2$，截距为 $7 - 4 \times 10/2 = -13$，即 $\hat{y} = 2x - 13$。当原始输入为 12 时，标准化输入为 1，两种表达都得到预测值 11。参数数值不同，但表示的是同一条预测规则。

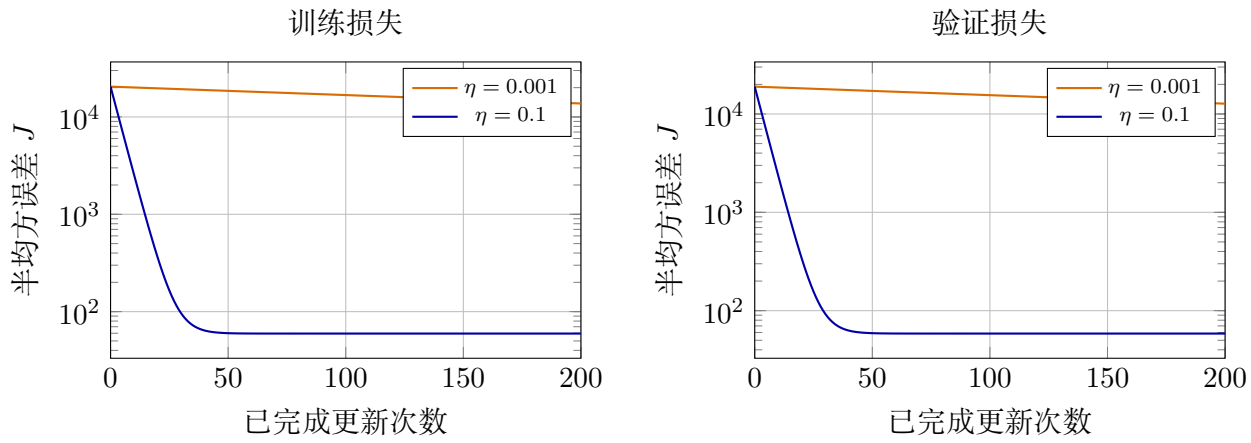
虽然两套坐标系给出的预测相同，但不同坐标系中的参数含义不同。w_z 表示输入增加一个训练标准差时，预测的变化量；b_z 表示原始输入等于训练均值时的预测。因此，当坐标系不同时，不能通过比较参数是否相等来判断模型是否一致；正确的做法是先转换坐标系，或者比较它们在相同原始输入上给出的预测。

对 T03 这类有截距、无正则化的线性模型，只要标准差非零，这个可逆变换仍能表达同一组直线。充分优化时，两种坐标可以得到相同预测；但梯度下降的路径及有限预算内的结果可能不同。这也说明标准化为什么能影响训练进展，而不必改变模型形式。

6. 从损失曲线检查训练与验证表现

6.1 在固定条件下比较学习率

下面的图使用 T03—T04 的 120 个合成批次，其中固定 80 个训练批次、40 个验证批次。训练输入按第 5 节标准化，两个运行都从 $w = 0, b = 0$ 开始，最多更新 200 次，唯一的区别是学习率，分别为 0.001 和 0.1。



左图为训练半均方误差，右图为验证半均方误差；图例中的 η 表示学习率。横轴是已完成更新次数。纵轴采用对数刻度，同样的竖直距离表示相同的倍数变化，而非相同的数值差。可以观察到，在这份数据和训练预算下，0.1 学习率的训练损失较快降到较低位置，而 0.001 学习率则下降缓慢，完成 200 次更新也没有低于 10^4 量级。

右图则展示了未参与梯度计算的验证集上的半均方误差，注意曲线形状与左图类似并不意味着两部分数据相同。

6.2 用参考结果判断训练是否充分

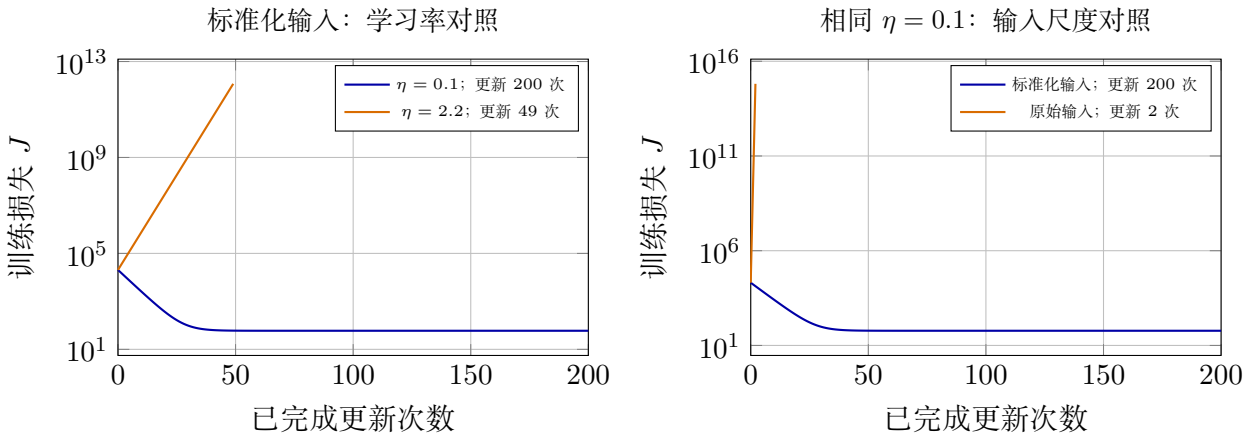
将训练后的参数在训练集和验证集上重新计算 RMSE，结果如下，保留三位小数：

方法	训练 RMSE	验证 RMSE
梯度下降，$\eta = 0.001$，200 次更新	165.819	159.563
梯度下降，$\eta = 0.1$，200 次更新	10.912	10.817
训练均值基线	56.672	67.555
训练最小二乘参考	10.912	10.817

可以看到小学习率的结果在当前预算下甚至不如均值基线，但同一线性模型的最小二乘参考明显更好。这说明本次小学习率运行尚未充分优化，不能据此宣布线性模型不适合这份数据。学习率为 0.1 时，训练 RMSE 与最小二乘参考在保留的三位小数的条件下是相同的，说明本次训练结果已接近参考最优值。

验证集 RMSE 则支持另一层判断：在这些固定验证批次上，0.1 的结果也优于基线和小学习率运行。这里已经利用验证结果比较候选，因此它不是独立最终测试表现。训练优化是否充分和目标场景中的预测是否可靠，仍然是不同的问题。

6.3 读清停止原因与实际更新次数



纵轴为对数刻度。保护性停止：训练损失 $J > 10^{12}$ 时停止；最后参数不作为有效模型。

这里给出两组包含提前终止现象的训练对照曲线。左图是标准化输入下不同学习率的训练曲线，右图则是相同学习率下原始输入与标准化输入的训练曲线。曲线展示了过大步长和输入尺度对训练可能的影响。

演示循环在训练损失非有限或大于 10^{12} 时停止，防止继续无效计算。这个阈值是保护条件，不是收敛判据。实际工程中遇到提前停止的运行应说明实际更新次数与停止原因。此外，即使用光了全部的训练预算，也不自动保证参数已经收敛。这一点可以参照 6.1 中低学习率的情况。

7. 本章小结：参数怎样逐步调整

损失函数的梯度为参数的局部调整提供了方向。对一元线性模型的半均方误差，斜率梯度为平均 $e_i x_i$，截距梯度为平均 e_i；两个梯度都由同一组参数和训练样本计算。学习率决定参数沿负梯度更新的幅度，更新后再检查损失，重复这个过程就形成梯度下降。

输入标准化改变参数坐标和优化条件，训练与验证应使用同一组由训练数据确定的变换。比较学习率时固定其他可变条件，如数据、初值、损失和预算等，才能进行归因。

上一章和本章以回归任务为例，介绍了模型、损失与参数更新。下一章将会切换到分类任务，继续探讨预测、损失与参数更新之间的关系。

8. 活动与实验查阅

8.1 用纸笔核对梯度与更新

配套纸笔活动的 T04 部分包含 B1—B5。第 2、3 节支持梯度与同步更新计算，第 4、6 节支持理解学习率与训练曲线，第 5 节支持尺度判断。

8.2 B02 的函数与已有支持

使用 B02 Notebook。数据读取、标准化、预测与损失函数、训练循环和结果展示均已提供。你需要补全 `gradient` 与 `step`，并解释自己实现的计算如何对应第 2、3 节。

先读已给函数。`predict` 接收一维数组 `x` 与标量参数，返回与输入形状相同的预测；`half_mse` 将预测减标签、平方、取平均，再除以 2，返回一个标量损失。`gradient` 应返回两个标量，分别对应斜率和截距的偏导数；`step` 接收旧参数、已算好的两个偏导与学习率，返回两个新参数。循环负责重复调用这些函数。

8.3 数组计算怎样保留样本对应

手写函数中的 `x` 和 `y` 都是形状 `(n,)` 的一维数组，每个位置对应同一条样本。标量乘加会分别作用于每个输入；同位置的预测与标签相减，得到同样形状的残差数组。逐元素计算残差与输入的乘积，再取平均，对应斜率偏导；残差直接取平均，对应截距偏导。

例如，另取 `x=[1, 2]`、`y=[2, 5]`，在 $w = 1, b = 0$ 时，预测为 `[1, 2]`，残差为 `[-1, -3]`，残差乘输入为 `[-1, -6]`。两个梯度分别为 -3.5 和 -2。若数组位置错位，计算的就不是这些样本的梯度。

形状也需要核对。列状预测 `(n,1)` 与一维标签 `(n,)` 相减，可能广播成 `(n,n)`，产生交叉相减；即使还能取平均得到数值，也不是原来逐样本计算的结果。B02 的手写函数保持输入、标签与预测均为一维。

参考模型调用 `LinearRegression` 时，输入采用库接口的二维形式 `(n,1)`。`x[:, None]` 保留所有样本，并增加一个长度为 1 的特征轴；例如 `[1, 2]` 变为 `[[1], [2]]`。这个转换只用于库接口，标签仍是一维，手写函数继续使用原来的输入形式。

8.4 识别代码中的输入坐标与训练范围

读取代码将原始训练输入记为 `xt`、验证输入记为 `xv`；由训练部分计算 `mu`、`sigma`，得到标准化数组 `zt`、`zv`。标签 `yt`、`yv` 保留原单位。函数参数虽然仍叫 `x`，正式训练传入的是 `zt`，因此函数中的 `w, b` 对应第 5 节的 w_z, b_z，而不是原始产量坐标的参数。

训练循环调用梯度函数时只传入训练输入与标签。验证输入、标签用于计算当前参数的验证损失，不参与梯度计算，也不参与本次实验的停止条件。

8.5 从小样本核对到学习率对照

先通过第 3 节三个样本的核对：预测、损失、两个梯度、新参数与新损失应相互一致。随后在固定批次数据上比较 0.001 与 0.1。两次从零初始化，使用同一标准化变换和 200 次更新预算；运行前写下预计现象，运行后用曲线或数值解释。

历史表的 `step=0` 是尚未更新的状态，`step=200` 表示已完成 200 次更新。正常完成预算时有 201 条记录；`budget_completed` 表示完成预算，`stopped_large_loss` 表示因异常损失停止。结果表用 `updates` 汇报已完成更新次数，解释前先看状态和次数，再比较训练与验证 RMSE。

完成 TODO 后删除该处 `raise NotImplementedError(...)` 停止提示，保留检查代码。在本人 Notebook 中填写实际结果和个人解释，重启内核并运行全部，注明辅助工具用途，按教师要求保存、备份并提交这一份文件。

9. 自查与迁移

先独立作答，再核对答案。计算可以保留分数。

1. 若某点 $g_w < 0$，梯度下降应使 w 增大还是减小？为什么不能据此保证任意大的学习率都降低损失？

2. 对 $x = [0, 2]$、$y = [1, 5]$，取 $w = 1, b = 0$，求两个梯度。用 $\eta = 0.1$ 完成一次同步更新，并计算新损失。

3. 两个梯度已由旧参数算好。先执行更新 `w` 的赋值，再用已算好的 `db` 更新 `b`，是否违反同步更新？若更新 `w` 后重算 `db`，又有什么不同？

4. 将半均方误差改为 MSE，保持参数、样本和学习率相同，梯度与一次更新的参数移动量怎样变化？最优参数是否改变？

5. 训练输入为 $[2, 6]$，验证输入为 $[10]$。按 `ddof=0` 求训练均值、标准差及训练和验证的标准化结果。为什么不单独标准化验证输入？

6. 若 $\mu = 4, \sigma = 2$，标准化模型为 $\hat{y} = 6z + 10$，写出等价的原始坐标模型，并核对原始输入 $x = 8$ 时的预测。

7. 两次学习率比较中，第二次从第一次的最终参数继续训练。这样的结果能否单独说明学习率的影响？应怎样安排？

8. 运行达到 200 次预算，且训练损失下降，是否同时证明已经收敛、验证误差下降以及未来预测可靠？应分别检查什么？

答案要点与回看位置

1. w 增大，因为减去负数等于加上正数。梯度描述局部变化，大步可能跨过低点，不能保证下降。回看第 1.1、3.1、4.1 节。

2. 预测为 $[0, 2]$，残差为 $[-1, -3]$，所以 $g_w = (0 - 6)/2 = -3$，$g_b = (-1 - 3)/2 = -2$。新参数为 $w = 1.3, b = 0.2$，预测为 $[0.2, 2.8]$，残差为 $[-0.8, -2.2]$，新损失为 $(0.64 + 4.84)/4 = 1.37$，小于旧损失 2.5。回看第 2.2、3.2 节。

3. 不违反，因为两个梯度仍来自同一组旧参数；赋值的先后不改变这一依据。若使用新 `w` 重算 `db`，两个偏导数就不在同一参数位置上，改变了本章的更新规则。回看第 3.3 节。

4. 两个梯度变成两倍；学习率相同时，参数移动量也变成两倍。目标乘以正的常数不改变最优参数集合，但这次更新后的损失是否下降仍要核对。回看第 2.2、4.1 节。

5. $\mu = 4, \sigma = 2$，训练坐标为 $[-1, 1]$，验证坐标为 3。验证与训练需要使用同一坐标；单独估计会改变变换，而且一个验证点的标准差为零。回看第 5.1—5.2 节。

6. $w_x = 6/2 = 3$，$b_x = 10 - 6 \times 4/2 = -2$，所以 $\hat{y} = 3x - 2$。$x = 8$ 时 $z = 2$，两种表达都预测 22。回看第 5.3 节。

7. 不能，因为同时改变了学习率和初始状态。每次重新初始化，保持数据、标准化、损失与更新预算相同，再比较结果。回看第 4.2、6.1、8.5 节。

8. 三者都不能由这个条件直接保证。达到预算只说明完成指定次数；训练是否接近最优可结合损失进展与同目标参考结果检查。验证误差应在验证样本上另算；未来可靠性还取决于评价对象与目标场景是否一致，选择后的最终检查需要独立证据。本单元没有独立测试集，因此不能把验证结果声明为最终测试表现。回看第 6.2—6.3、8.5 节及 T02。