T05 逻辑回归与分类损失

从分数、概率到类别

机器学习课程学生讲义

辅修版 · 2026 年 10 月 24 日

学生讲义 · 辅修版。对应 T05（2 理论学时），完成 T06 后进入 B03（2 实验学时）。

导读

在 T03 中，我们介绍了使用一元线性模型预测批次总能耗的方法，随后在 T04 说明了怎样根据损失调整一元线性模型的参数。在对应的实验中，我们首先完成了一次完整的计算损失 → 计算梯度 → 更新参数的流程，随后重复了 200 次这个流程，完成了一次完整的模型训练，并将结果与最小二乘法求得的参考结果进行了对比确认。这样，我们实际上已经完成了一次回归模型的训练与验证。

现在我们切换任务类型。仍然是在生产批次开工前作预测的情境，但预测的具体问题改为这个批次完工后的能耗是否超限。预测时点和对象没有改变，输出却从一个能耗数值变成了类别。根据 T01 的说明，这种类型的任务是分类任务。再次提示，即使将正常与超限类别分别编码为 0 和 1，任务的性质不会改变。

本章的二分类模型先根据输入计算一个分数，再将它转换为超限概率，最后按预先约定的阈值决定类别。要注意到的是，在这个模式下，模型对两条记录最终的汇报结果相同并不意味着对它们的实际判断完全相同。例如，两条记录经过转化后超限的概率分别为 0.55 和 0.95 时，模型对这两条记录的最终预测都是超限批次，但是概率不同意味着模型对这个判断的确定性是不同的。除此之外，根据我们承担漏报与误报的意愿，对于二分类问题，最终输出的类别甚至可以不是概率最高的类别，而是正类的概率是否超过某个阈值。例如，假如提前约定超限概率超过 0.4 就要发出提示，那么超限概率 0.45 的批次也要预测为超限批次。

本章将把概率估计和类别决定分开，解释模型怎样产生概率，以及训练和决策分别在改变什么。本章的具体流程为：

> 用输入计算一个分数 → 将分数转换为超限概率 → 按阈值决定类别 → 用真实标签检查概率与误判。

与回归任务类似，我们仍然先根据模型和初始参数计算预测，然后根据训练标签计算损失，再根据损失计算梯度，最后结合梯度和学习率调整参数。阅读后，你应该能区分分数、概率和类别，完成给定数值的概率转换与阈值判断，计算简单的二分类交叉熵，并解释改变阈值为什么可能改变误报、漏报，却不会自动改变模型参数。

1．从能耗数值预测转向是否超限

1.1 输入、标签与输出的含义

本章的例子，即开工前预测一个批次是否属于超限批次，是一个典型的二分类任务。其中超限为正类，标签 $y = 1$ 表示实际超限，$y = 0$ 表示实际正常。标签仍在完工后取得，输入则必须在开工前已知，例如每个批次的计划产量。

一个二分类模型可以输出超限概率，记为 p。这里 p 表示模型对当前输入属于类别 1 的概率估计，类别 0 的概率则为 $1 - p$。例如 $p = 0.8$ 时，模型给超限类别的估计概率为 0.8，给正常类别的估计概率为 0.2。两者相加为 1，描述的是同一个对象的两种互斥类别。

概率与实际标签承担不同工作。一个批次完工后实际超限，标签就是 1；模型预测时可能输出 0.8、0.6 或其他数值。这些数值并不代表对应的批次处于“部分超限”的状态，而是模型在尚不知道结果时给出的超限类别的估计概率。取得真实标签后，才有依据检查估计得怎样。

1.2 线性表达式与分数

很多表达式的输出并不符合概率的要求。例如线性表达式 $wx + b$，其结果可以是任意实数，例如负数或大于 1 的数，因而不满足概率的要求。一般将这类表达式的直接输出结果称为分数，记为 s：

$$s = wx + b.$$

这里 x 是当前批次的输入，w, b 是模型参数。得出的分数 s 既不是预测类别，也不是预测概率。后续需要通过计算，将分数 s 转换为满足条件的概率。注意区分分类分数 s 与 T04 中的标准化输入 z。

如果有多个输入，分数可以写成：

$$s = \sum_{j=1}^{n} w_j x_j + b.$$

这里 d 是输入数量，j 是输入编号。例如，x_1 是开工前确定的计划负荷比例，x_2 是开工前已取得的环境指数。取 $w_1 = 2, w_2 = 1, b = -1$，当 $x_1 = 0.6, x_2 = 0.2$ 时，分数为 $2 \times 0.6 + 1 \times 0.2 - 1 = 0.4$。两个特征共同参与一个分数的计算，每个特征都有自己的系数，同一个模型对不同批次仍使用同一组参数。

多个输入的线性表达式也可以写成向量形式：$s = \boldsymbol{w}^{\mathsf{T}}\boldsymbol{x} + b$，其中 $\boldsymbol{w}$ 和 $\boldsymbol{x}$ 分别是按相同顺序排列的系数与特征，T 表示转置。这个记号表达的仍是逐项相乘再相加。后续章节仍以一元线性表达式作为示例讲解，多个输入的表达式可以使用类似的方法。

2. 用 Sigmoid 函数将分数转换为概率

2.1 转换函数怎样工作

逻辑回归使用 Sigmoid 函数，将分数 s 转换为概率：

$$p = \sigma(s) = \frac{1}{1 + \exp(-s)}.$$

这里 $\exp(a)$ 表示 e^a。指数函数的值始终大于 0，因此分母大于 1。当分数 s 有限时，转换的结果 p 始终在 0 与 1 之间，符合概率的取值范围，因而可以用来表示给定输入时的超限概率估计。

先看 $s = 0$。因为 $\exp(0) = 1$，所以 $p = 1/(1+1) = 0.5$。若分数增大，$-s$ 减小，$\exp(-s)$ 随之减小，分母变小，概率就增大。若分数减小，概率则减小。Sigmoid 因此是单调递增的：分数越高，模型估计的超限概率越高。

分数 s	$\exp(-s)$（约值）	概率 p（约值）
-4	54.598	0.018
-2	7.389	0.119
-1	2.718	0.269
0	1	0.500
1	0.368	0.731
2	0.135	0.881
4	0.018	0.982

分数增大时，概率逐渐接近 1；分数减小时，概率逐渐接近 0。但转换后的概率变化并不始终与分数变化成正比：分数接近 0 时，相同的分数变化会带来较明显的概率变化；分数处于很大的正值或很小的负值时，概率分别接近 1 或 0，变化会比较小。

2.2 从输入到概率完成一次计算

对一元模型取 $w = 2, b = -1$。当输入为 $x = 0.25$ 时，分数为：

$$s = 2 \times 0.25 - 1 = -0.5.$$

给定 $\exp(0.5) \approx 1.649$，概率为：

$$p = \frac{1}{1 + 1.649} \approx 0.378.$$

当输入改为 $x = 0.75$ 时，分数为 0.5。给定 $\exp(-0.5) \approx 0.607$，概率为 $1/(1 + 0.607) \approx 0.622$。两个对象使用相同参数，输入不同使分数不同，进而使概率不同。

虽然名称中有“回归”，但逻辑回归是一种分类方法。本章介绍的二分类逻辑回归先计算线性分数，再通过非线性的 Sigmoid 得到类别概率；此前的线性回归则直接输出能耗预测值。两者的输出含义与学习任务不同。

3. 用阈值把概率转换为类别

3.1 阈值定义类别判断规则

概率可以表达不同程度的倾向，但如果实际工作中需要明确的类别输出，则还需要规定当一条记录的预测超限概率 p 至少为多少时将这条记录明确预测为超限批次。这个界限称为分类阈值，记为 t。本课程约定：

$$\hat{y} = \begin{cases} 1, & p \geq t, \\ 0, & p < t. \end{cases}$$

$\hat{y}$ 在本章表示预测类别，取值为 0 或 1；它与表示概率的 p 不同。等于阈值时判为 1，是本课程统一采用的约定。

阈值 0.5 是常见起点。按这个阈值，第 2.2 节的两个概率 0.378 与 0.622 分别得到类别 0 与 1。如果把阈值提高到 0.7，两者都会判为 0。这个改动只发生在概率之后：参数、分数和概率都没有改变，改变的是根据已有概率作出类别决定的规则。

3.2 固定概率，检查阈值改变了哪些对象

考虑另一个四批次示例。概率由同一个已训练模型给出，完工后取得的标签用来核对结果：

批次	实际标签 y	超限概率 p	$t = 0.5$ 时的类别	$t = 0.4$ 时的类别
甲	1	0.80	1	1
乙	1	0.45	0	1
丙	0	0.65	1	1
丁	0	0.10	0	0

阈值 0.5 时，甲是真正例，乙是假负例，丙是假正例，丁是真负例，所以 TP、FN、FP、TN 各为 1。精确率与召回率均为 1/2。阈值降到 0.4 后，乙由漏报变为正确识别，TP 为 2、FN 为 0，FP 和 TN 仍为 1。精确率变为 2/3，召回率变为 1。

在固定概率下，降低阈值会保留原来所有的正类预测，并可能增加新的正类预测。新增对象中，实际超限的对象会减少漏报，实际正常的对象会增加误报。因此，漏报数量不会增加，误报数量不会减少。漏报和误报的数量也可能都不变，例如没有新的记录落入新的概率区间时。相应地，提高阈值会使正类预测的集合缩小或保持不变，因此误报数量不会增加，漏报数量不会减少。

这个示例中精确率提高，是因为新增的正类预测恰好是真正例。如果新增对象大多实际正常，精确率就可能下降。阈值降低并不保证精确率按一个固定方向变化。是否值得降低阈值，需要结合漏报后果、误报成本与人工复核能力判断，而不只是检查某个指标有没有提高。

4. 用交叉熵评价概率预测

4.1 输出类别不是全部的预测信息

设某个批次实际超限，标签为 1。两个模型分别给出 0.6 和 0.9 的超限概率，当阈值是 0.5 时两个模型的类别预测均正确，因而准确率无法在这个批次上区分这两个模型。但这两个模型对真实类别给予的支持程度不同，也就是对判断的确定程度不同。第一个模型只是比较偏向该批次超限，而第二个模型则非常确信该批次超限，为了区分这两种情况，我们需要一种直接使用概率，因而能够分辨这些差异的损失函数。

此外，阈值后的类别是离散的。例如，参数改变使预测概率从 0.6 变为 0.61，预测类别和类别错误数都保持不变。若直接以类别错误数作为训练目标，参数的小幅变化通常无法提供有效的梯度信息，难以据此确定调整方向。

为了解决这两个问题，逻辑回归通常使用直接基于概率的分类交叉熵作为损失函数。

4.2 给真实类别的概率越小，损失越大

记模型对真实类别的预测概率为 q。对于我们的二分类示例，当 $y=1$ 时，$q=p$；当 $y=0$ 时，$q=1-p$。单个样本的交叉熵损失定义为：

$$\ell = -\ln q.$$

ℓ 读作 “ell”，表示单样本损失。因为 $0<q<1$，$\ln q$ 为负数，取负号后损失为正值。

本章用到的对数值见下表：

给真实类别的概率 q	损失 $-\ln q$（约值）
0.9	0.105
0.8	0.223
0.5	0.693
0.2	1.609
0.1	2.303

给真实类别的概率越大，损失越小，反之亦然。当真实类别的概率接近 1 时，损失接近 0，而当真实类别的概率接近 0 时，损失趋向正无穷。实际超限却输出 $p=0.1$，意味着模型更倾向于正常，真实超限类别只得到 0.1 的概率，这时损失约为 2.303。实际超限且输出 $p=0.9$ 时，损失则只有约 0.105。

再次提示，对实际正常的批次，计算时应使用正常概率 $1-p$。例如 $y=0, p=0.9$，模型给真实正常类别的概率只有 0.1，损失同样约为 2.303。损失关心的是分给真实类别的概率，而不是一律认为较大的 p 更好。

4.3 将两种标签情况写成同一个公式

对于二分类任务，标签只有 0、1 两种取值，因此可以把上面的计算进一步合并为：

$$\ell(y,p) = -[y\ln p + (1-y)\ln(1-p)].$$

当 $y=1$ 时，第一项保留，第二项的系数为 0，得到 $-\ln p$；当 $y=0$ 时，第一项的系数为 0，第二项保留，得到 $-\ln(1-p)$。这个公式并没有增加新的判断规则，只是用标签选择应计算的那一项。

对 n 个训练样本取平均，得到平均交叉熵损失：

$$L = \frac{1}{n}\sum_{i=1}^{n}\ell(y_i,p_i) = -\frac{1}{n}\sum_{i=1}^{n}[y_i\ln p_i + (1-y_i)\ln(1-p_i)].$$

本章用 L 表示平均交叉熵，区别于 T03—T04 的半均方误差 J。下标 i 仍用于对应样本：每个概率都要与同一批次的真实标签比较。p_i 是模型参数和输入共同决定的，因此调整参数会改变概率，也会改变损失。

4.4 计算平均损失，并检查阈值的作用

取三个样本，真实标签为 $[1,0,1]$，模型预测的正类概率为 $[0.9,0.2,0.5]$。因此给出真实类别的概率分别为 $[0.9,0.8,0.5]$，损失约为 $[0.1054,0.2231,0.6931]$。平均交叉熵为：

$$L \approx \frac{0.1054+0.2231+0.6931}{3} \approx 0.341.$$

阈值 0.5 时，预测类别为 $[1,0,1]$，三个判断都正确。阈值改为 0.7 时，预测变为 $[1,0,0]$，第三个样本成为漏报。但计算交叉熵所用的标签和概率没有变化，所以平均损失仍约为 0.341。

交叉熵衡量概率预测，混淆计数及精确率、召回率衡量某个阈值下的类别判断。它们回答不同问题，可以共同用于解释结果。采用交叉熵，是为了给概率训练提供相应目标，并不意味着概率预测在数学上只能使用这一种损失。

5. 训练改变参数，阈值改变决策

5.1 用梯度下降训练逻辑回归

给定参数以后，先用训练输入计算分数，再转换为概率，最后根据训练标签计算平均交叉熵。与 T04 相同，训练根据损失对参数的梯度更新参数，然后重新计算预测与损失。变的是预测输出和损失形式，保留的是“预测 → 损失 → 梯度 → 更新”的联系。

对于 Sigmoid 与二分类交叉熵的组合，单样本损失对分数的导数可以写成：

$$\frac{\partial \ell}{\partial s} = p - y.$$

注意这个关系给出的调整方向：无论真实类别是哪个，它都倾向于增加真实类别的预测概率。例如，当 $y=1, p=0.2$ 时，导数为 -0.8，在分数这个变量上沿负导数方向移动会使分数增大，进而提高

超限概率；$y = 0, p = 0.8$ 时，导数为 0.8，对应降低分数的方向，进而降低超限概率，提升正常概率。这部分内容在后面的分类网络训练中会再次提到。

实际训练调整的是多个样本共用的参数。不同样本可能对参数提出不同的调整方向，因此仍需汇总训练样本的梯度，再按学习率更新。一次更新并不保证每个样本的概率都向有利方向变化，训练目标是降低整体训练损失。

5.2 阈值可以选择，但选择也需要评价依据

阈值不出现在上述交叉熵公式中。因此，在模型参数和输入保持不变时，只改变阈值不会改变分数、概率或交叉熵，只会改变从概率到类别的判断。重新训练调整的是模型参数，调整阈值改变的是类别决定规则。若重新训练使概率发生变化，原先阈值的效果也需要重新检查。

如果希望选择适合任务的阈值，可以在验证集上比较少量事先确定的候选，记录漏报、误报与相关指标，再结合实际代价作选择。这时验证结果已经参与决策，应遵守 T02 的数据分工：选择后的表现不能同时作为完全独立的最终测试证据。

5.3 概率的含义需要用数据检查

模型输出 $p = 0.8$，表达的是当前模型对超限概率的估计，不能仅凭这个数值证明某个批次的真实超限风险就是 80%。如果要检查概率数值是否可信，需要在适当数据上观察：被模型赋予相近概率的对象，实际超限比例是否也接近这个数值。例如许多预测约为 0.8 的批次中，实际超限比例接近 80%，才能提供相应的支持。

当前小样本计算帮助理解转换与损失，并未完成这种概率可靠性检查。用于真实生产决策时，还要考虑数据是否代表当前设备与生产条件，以及提示后能够采取什么行动。概率估计、类别判断和后续生产决策，各自需要相应证据。

6. 本章小结：分开概率估计与类别决定

本章的二分类逻辑回归先用输入计算线性分数，再通过 Sigmoid 得到正类概率。分类阈值把概率转换为类别，因此分数、概率和类别是同一流程中的三个不同量。0 和 1 是类别编码，概率则表示模型对类别的估计。

二分类交叉熵根据模型给真实类别的概率计算损失，能够区分阈值后同样正确的预测，也会对偏向错误类别的自信预测给出较大的损失。训练用这个目标调整参数；训练完成后固定参数，只改阈值，只改变类别判断，不改变概率和交叉熵。阈值比较要回到误报、漏报和实际代价，并说明使用了哪些数据。

T06 将继续讨论模型拟合与泛化：即使训练损失已经很低，模型在新数据上的表现仍可能不理想。正则化通过在训练目标中加入约束，改变参数选择的依据。

7. 活动与实验查阅

7.1 用纸笔串起分数、概率、损失与类别

配套纸笔活动的 A 部分练习分数到概率的转换，第 2、3 节提供计算与判断依据。B 部分在固定概率上比较阈值，可按第 3.2 节的方法逐行判断，再统计混淆计数。C 部分计算交叉熵并解释阈值的作用，对应第 4 节。

先区分题目给出的是输入、分数还是概率，再确定下一步计算。计算损失时使用真实标签与概率，计算混淆计数时使用真实标签与预测类别。这个区分能帮助定位错误：如果改阈值后交叉熵也改变了，就应检查是否把类别代入了概率的位置。

7.2 为 B03 的分类观察作准备

完成 T06 后，使用 B03 Notebook。其中分类部分提供模型训练与结果展示，用来观察正类概率、阈值和误判之间的关系。阅读分类代码时，先找到输出超限概率的步骤，再找到按阈值生成类别的步骤，确认两次阈值比较使用的是同一组概率。

本章的纸笔计算提供结果解释的依据：概率为何处于 0 与 1 之间，降低阈值怎样改变正类预测，为什么需要同时查看 FP 和 FN。B03 的正则化部分由 T06 提供理论支持；此处先完成概率与类别的理解。

8. 自查与迁移

先独立作答，再核对答案。所需指数与对数值已经给出。

1. 超限用 1、正常用 0 编码，为什么仍是分类任务？分数 s、概率 p 和预测类别 $\hat{y}$ 分别表示什么？

2. 给定 $s = \ln 4$，且 $\exp(-\ln 4) = 1/4$，求 p。阈值分别为 0.5、0.9 时，预测类别是什么？模型参数是否必须随之改变？

3. 对真实标签 $[1, 0, 1, 0]$、概率 $[0.7, 0.4, 0.3, 0.1]$，分别按阈值 0.5 和 0.3 写出类别与 TP、FP、FN、TN，计算精确率和召回率。

4. 第 3 题降低阈值后，精确率是否提高？这与第 3.2 节的示例有什么不同？

5. 真实标签为 $[0, 1]$，概率为 $[0.9, 0.9]$。给定 $-\ln 0.1 \approx 2.303$、$-\ln 0.9 \approx 0.105$，求两个单样本损失与平均交叉熵。如果只把阈值从 0.5 改为 0.95，损失是否改变？

6. 若 $y = 0, p = 0.8$，给定 $\partial \ell / \partial s = p - y$，在分数上沿负导数方向移动，会让分数与超限概率怎样变化？为什么这个方向与真实标签一致？

7. 一个模型对某批次输出 $p = 0.8$，能否据此证明该批次真实超限风险为 80%？若根据验证集选择了阈值，选择后的验证指标是否属于独立最终测试结果？

答案要点与回看位置

1. 0、1 表示预先定义的类别，不表示能耗数量。s 是线性表达式产生的分数，可以取任意实数；p 是模型估计的超限概率；$\hat{y}$ 是按阈值决定的类别。回看第 1.1—1.2、2.1、3.1 节。

2. $p = 1/(1 + 1/4) = 0.8$。阈值 0.5 时判 1，0.9 时判 0；固定模型只改阈值，不必改变参数、分数和概率。回看第 2.1、3.1 节。

3. 阈值 0.5 时，类别为 $[1, 0, 0, 0]$，TP=1、FP=0、FN=1、TN=2，精确率为 1、召回率为 1/2。阈值 0.3 时，类别为 $[1, 1, 1, 0]$，TP=2、FP=1、FN=0、TN=1，精确率为 2/3、召回率为 1；第三个样本恰好等于阈值，判为 1。回看第 3.1—3.2 节及 T02 第 5 节。

4. 没有，精确率从 1 降到 2/3。新增的正类预测同时包含一个真正例和一个假正例，而第 3.2 节只新增了真正例。降低阈值使漏报不增、误报不减，但精确率不保证单调变化。回看第 3.2 节。

5. 第一个样本的真实类别概率为 $1 - 0.9 = 0.1$，损失约 2.303；第二个为 0.9，损失约 0.105。平均损失约 $(2.303 + 0.105)/2 = 1.204$。只改阈值不改变用于损失计算的标签与概率，因此损失不变。回看第 4.2—4.4 节。

6. 导数为 0.8，沿负导数方向小幅移动使分数下降，Sigmoid 的单调性使超限概率也下降，正常概率上升。这与真实标签为正常一致；这里只判断分数上的局部方向，不证明共享参数更新后所有样本都会改善。回看第 2.1、5.1 节。

7. 不能。0.8 是模型估计，需要适当数据检查概率数值的可靠性。阈值若根据验证结果选择，验证数据就参与了决策；这些结果可以支持本次选择，但不属于独立于选择过程的最终测试。回看第 5.2—5.3 节及 T02。