# T06 正则化与模型复杂度

在拟合与约束之间选择

机器学习课程学生讲义

辅修版 · 2026 年 10 月 25 日

学生讲义 · 辅修版。对应 T06（2 理论学时），之后完成 B03（2 实验学时）。

## 导读

T03—T04 说明了怎样通过调整参数降低训练损失，T05 将这个过程扩展到分类概率与交叉熵。我们已经知道，训练是否充分，需要结合训练目标检查；模型对未参与训练的对象预测得怎样，则需要另外的评价证据。T02 曾介绍过拟合：模型过度适应训练数据中的噪声或特有细节，导致其在训练数据上表现很好，却在新数据上表现较差。本章将进一步讨论，如果训练拟合改善了，验证表现却没有相应改善，哪些迹象提示可能发生了过拟合，还应检查哪些原因？如果问题确实来自过拟合，训练时又可以怎样加以限制？

本章介绍一种直接修改训练目标的方法：在原有的预测误差之外，加入一项对系数大小的惩罚，使训练同时考虑拟合误差与参数代价。这是正则化的一种常见方式。惩罚的强度可以改变，但更强的限制未必带来更好的预测：限制太弱可能保留对偶然模式的适应，限制太强也可能使模型无法充分利用有用关系。

> 检查训练与验证表现 → 在训练损失中加入参数惩罚 → 比较少量预设强度 → 在相同验证条件下选择 → 解释改善与局限。

完成本章后，你应该能解释欠拟合与过拟合的迹象，计算平方误差与参数惩罚组成的训练目标，说明特征尺度为何影响惩罚，并区分岭回归的系数收缩与 Lasso 的稀疏作用。

## 1. 训练误差下降以后，还需要检查什么

### 1.1 拟合能力与新数据表现

训练数据既包含能够迁移到新对象的关系，也可能包含有限样本中的随机波动。例如，少量批次中某个环境测量恰好与能耗一起变化，但换一批记录后这种关系不再成立。如果模型利用了这个偶然关系，就可能降低训练误差，却不能改善新对象的预测。这是 T02 所讨论的过拟合的一种来源。

模型能够表达哪些预测关系，与它的形式、输入和参数约束有关。这些因素共同影响模型复杂度，也就是模型能够表达的关系有多灵活。本章用“拟合能力”描述模型表达关系和适应数据的能

力。允许使用更多特征，或者放宽参数约束，可能使模型更容易适应训练记录。但能够更细致地拟合已有记录，并不意味着学到的都是可以迁移的关系。

模型形式或约束过于严格，连数据中有用的变化也难以表达，训练和验证表现都受限制，这种情况称为欠拟合。例如，能耗明显随产量变化，却始终使用一个常数作预测，可能在训练集和验证集上都留下较大误差。判断这里的误差是否较大，要结合任务要求与合理候选比较，而不是规定一个适用于所有数据的数值界限。

### 1.2 从同一评价安排中观察迹象

下面是一组假设结果，三个方案使用相同训练集、验证集和 MAE，标签单位也相同。这些数值用来解释判断，不是 B03 的运行输出。

| 方案 | 训练 MAE | 验证 MAE |
|---|---|---|
| A | 8 | 9 |
| B | 3 | 4 |
| C | 1 | 7 |

方案 A 在两部分数据上都比方案 B 差，提示其拟合可能不足；方案 C 虽然训练误差最小，验证误差却明显高于方案 B，提示其可能过度适应训练记录。如果事先采用验证 MAE 选择，这组结果支持选择方案 B。

这些迹象需要结合训练过程解释。方案 A 的结果也可能来自尚未训练充分，方案 C 的训练与验证差距也可能受到数据分布变化的影响。T04 讨论的优化是否充分，与这里讨论的拟合是否有利于泛化，是相关但不同的问题。正则化用于调整拟合的约束，不能代替对训练流程和数据质量的检查。

## 2. 把参数惩罚加入训练目标

### 2.1 预测误差与参数大小承担不同工作

先回到连续数值预测。设有 $n$ 个训练样本，每个样本有 $d$ 个特征。第 $i$ 个样本的预测为：

$$\hat{y}_i = \sum_{j=1}^{d} w_j x_{ij} + b.$$

$i$ 标记样本，$j$ 标记特征，$x_{ij}$ 是第 $i$ 个样本的第 $j$ 个特征，$w_j$ 是对应系数，$b$ 是截距。与 T03 相同，训练半均方误差为：

$$J_{\text{data}} = \frac{1}{2n} \sum_{i=1}^{n} (\hat{y}_i - y_i)^2.$$

这里增加下标 data，表示这一部分只汇总数据上的预测误差。为了限制参数，在它之外加入系数平方和，得到新的训练目标：

$$J_\lambda = J_{\text{data}} + \frac{\lambda}{2}\sum_{j=1}^{d} w_j^2, \qquad \lambda \geq 0.$$

$\lambda$ 是控制参数惩罚强度的参数。固定 $\lambda$ 时，系数平方和越大，惩罚越大；固定系数平方和时，$\lambda$ 越大，惩罚越大。系数平方和也记为 $\|\boldsymbol{w}\|_2^2$，它的平方根 $\|\boldsymbol{w}\|_2$ 称为系数的 L2 范数，用一个数描述整组系数的大小。

原先只要减小训练平方误差，就能改善目标；现在，如果降低误差需要较大的系数，还要检查误差的减少是否足以抵消惩罚的增加。用这种平方惩罚训练线性回归模型，得到的就是岭回归，也称带 L2 正则化的线性回归。

## 2.2 为什么要限制系数，以及为什么不惩罚截距

对于相同尺度的输入，较大的系数意味着模型会放大该特征的变化。如果训练集里某个特征的偶然波动与标签碰巧相关，模型可能通过给它较大的系数来贴合这些记录。平方惩罚使这样的拟合需要付出额外代价，从而改变训练选择参数的依据。

这并不意味着所有大系数都没有用。有用关系也可能需要较大的系数，因此限制会同时影响模型对真实关系和偶然变化的适应。正则化是否改善预测，仍要看合理验证下的结果；惩罚只是提供一种选择参数的偏好，而不是预先知道哪些关系是真实的。

本章的惩罚只包括特征系数，不包括截距 $b$。截距主要调整预测的整体水平。例如，把能耗的记录整体增加一个常数，只需相应调整截距，并不需要让模型对输入变化变得更敏感。通常保留这种整体平移的自由，而对特征系数施加约束。后面的公式与 B03 均沿用不惩罚截距的约定。

## 2.3 一个完整的目标值比较

假设在同一份已统一尺度的训练数据上，有两组候选参数：

| 方案 | 训练半均方误差 $J_{\text{data}}$ | 系数 $\boldsymbol{w}$ | 系数平方和 |
|---|---|---|---|
| A | 1 | $[2, 4]$ | $2^2 + 4^2 = 20$ |
| B | 2 | $[1, 1]$ | $1^2 + 1^2 = 2$ |

当 $\lambda = 0$ 时，惩罚为 0，方案 A 的目标为 1，方案 B 为 2，方案 A 更小。当 $\lambda = 0.2$ 时：

$$J_{0.2}(\text{A}) = 1 + \frac{0.2}{2} \times 20 = 3,$$
$$J_{0.2}(\text{B}) = 2 + \frac{0.2}{2} \times 2 = 2.2.$$

这次方案 B 的目标更小。方案 B 虽然对训练数据拟合得稍差，却用小得多的系数减少了惩罚。本例是在两组给定参数之间比较，不表示已经求出了全部参数中的最优解，也没有给出验证表现。

比较时还要固定 $\lambda$。方案 A 在 $\lambda = 0$ 下的目标 1，不能直接与方案 B 在 $\lambda = 0.2$ 下的目标 2.2 比大小，再宣称前者方案更好，因为两个数采用了不同的训练标准。跨强度选方案，要回到相同验证样本和相同评价指标。

# 3. 惩罚强度改变拟合，但不直接决定泛化

## 3.1 从不加惩罚到较强约束

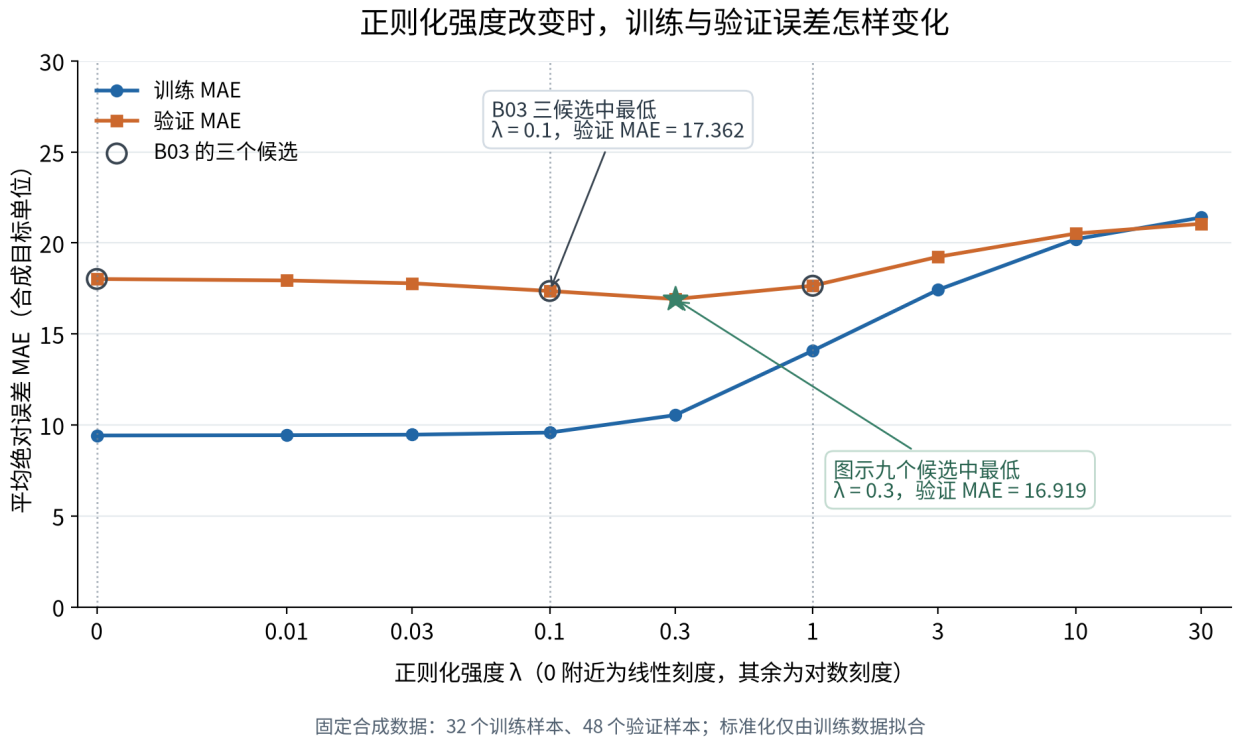
$\lambda = 0$ 时，目标回到普通最小二乘的半均方误差。它表示没有加入这一项系数惩罚，并不表示模型一定过拟合。是否过拟合还与样本数量、噪声、特征及模型形式有关。

增大 $\lambda$ 后，训练会更重视系数大小。在相同数据、特征尺度及求解充分的条件下，岭回归倾向于把整组系数向零收缩。当系数受到很强限制时，预测随输入变化的幅度减小，模型可能难以表达本来有用的变化，从而出现欠拟合。

注意，这里收缩描述的是整组参数受到的作用，不能理解为所有系数必定按相同比例缩小，或每个系数的绝对值都随强度逐个单调下降。不同特征之间可能相互补偿。实验显示系数范数，是为了观察整体变化，而不是仅凭某个系数判断泛化好坏。

## 3.2 从曲线观察拟合与验证表现

下面使用 B03 的固定合成数据观察强度变化：32 个训练样本、48 个验证样本，标准化只从训练数据估计。图中九个强度点均来自实际拟合，每个候选在同一训练集上重新训练，再对同一验证集计算 MAE。连线只帮助观察，不表示已经计算了所有中间强度。




固定合成数据上九个正则化强度的训练与验证 MAE

横轴在 0 附近使用线性刻度，其余使用对数刻度，以同时展示不加惩罚和相差多个数量级的强度。相邻横坐标的距离不表示相同的强度差。

先从左向右观察两条线。在不加惩罚的位置，训练 MAE 较低，验证 MAE 却不是最低。适当增大强度后，训练 MAE 略有升高，验证 MAE 反而下降。这说明对训练记录拟合得更紧，并不总

能改善对未参与训练对象的预测；适当限制在这次数据上有帮助。

继续向右，两条线都升高，与约束过强、拟合不足的情况一致。在较强约束下，训练与验证 MAE 还逐渐接近，但此时二者的数值都较高。因此，差距缩小本身不能说明模型改善，还要检查误差是否满足任务需求。

图中圆圈标出 B03 原定的三个候选，星号标出九个图示候选中的最低验证误差。两者的最好结果不同，说明选择结论需要交代候选范围。图示扩展用于观察变化，第 6 节再根据原定三个候选的具体数值完成选择。

这组数据的验证 MAE 先下降后上升，但实际结果并不保证呈现整齐的 U 形。样本较少时，指标可能波动或并列，应按实际结果解释，而不是更换划分或强度凑出预期图像。

### 3.3 学习率、正则化强度与阈值的区别

这三个设置都可能影响最终看到的结果，但作用的位置不同。学习率决定参数更新时走多远；正则化强度改变训练目标对参数的偏好；分类阈值决定已有概率怎样变成类别。调整学习率，是改变寻找参数的过程；调整正则化强度，是改变要寻找哪一种参数；固定模型改阈值，则不改变已经训练出的参数和概率。

因此，比较正则化强度时需要为每个候选重新训练，不能只修改一个显示数值或分类阈值。保持其他条件一致，才能判断这次训练目标的改变带来了什么结果。

## 4. 特征尺度为什么会改变参数惩罚

### 4.1 相同预测可能对应不同的系数大小

设一个长度特征用米表示，预测关系为 $\hat{y} = 3x$。如果改用厘米，输入变为 $x' = 100x$，同一关系写成 $\hat{y} = 0.03x'$。例如 $x = 2$ 米与 $x' = 200$ 厘米，两式都预测 6。

预测相同，系数平方却分别为 $3^2 = 9$ 和 $0.03^2 = 0.0009$，相差一万倍。如果直接使用相同的 $\lambda$ 惩罚原始系数，就会给这两个等价表达不同的代价。对同一个物理量，换单位后输入数值增大，表达相同预测所需的系数就相应减小。因此，不能脱离输入尺度理解系数大小。

当多个特征单位或量级不同时，直接对原始系数一视同仁地惩罚，会使约束受到计量方式影响。要让平方惩罚在可比较的坐标上发挥作用，通常先统一输入尺度，再训练岭回归。本章与 B03 都采用标准化后的坐标。

### 4.2 标准化只从训练数据估计

沿用 T04，对每列特征分别用训练均值和训练标准差变换：

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}.$$

$\mu_j$ 和 $\sigma_j$ 来自第 $j$ 列训练数据，$z_{ij}$ 是变换后的输入。验证数据使用相同的 $\mu_j, \sigma_j$，不另行估计。本章的例子假设所用特征的训练标准差大于 0。

例如，另一小表的训练输入为 $[1,5]$。按总体标准差的计算约定，均值为 3，标准差为 2，因此训练坐标为 $[-1,1]$。验证输入为 7 时，用同一变换得到 $(7-3)/2=2$。

如果把验证输入也加入估计，均值会变成 13/3，训练记录转换后的坐标也随之改变。此时验证数据虽然没有提供标签，却已参与确定训练模型使用的输入变换。若要按 T02 的安排保留验证分工，就应先划分，再只用训练数据拟合变换。

### 4.3 在哪一套坐标上解释惩罚

标准化以后，预测式中的系数乘的是 $z_{ij}$，惩罚也应对这些系数计算。它们描述输入增加一个训练标准差时预测的变化，而不是原始输入增加一个物理单位时的变化。即使两套参数表达相同预测，也不能把原始坐标的系数代入标准化坐标的惩罚，再与程序输出核对。

T04 中标准化帮助改善参数更新受尺度影响的情况；本章增加了另一层理由：它改变不同特征在参数惩罚中的可比性。标准化没有消除数据中的噪声，也没有保证验证误差会降低，它只是让本次训练目标在明确的坐标上计算。

## 5. 岭回归、Lasso 与分类中的正则化

### 5.1 收缩与稀疏是不同作用

岭回归使用系数平方和作为惩罚。另一种常见方法是 Lasso，它把平方和改为系数绝对值之和。例如采用下面的目标约定：

$$J_{\text{Lasso}} = J_{\text{data}} + \lambda \sum_{j=1}^{d} |w_j|.$$

绝对值之和也记为 $\|\boldsymbol{w}\|_1$，称为 L1 范数。两种方法都使较大的系数付出代价，但惩罚在零点附近的形状不同：平方在接近零时逐渐变平，绝对值在零点有一个尖角。

具体地说，当一个系数向零靠近、绝对值减小时，绝对值惩罚的减少量始终等于 $\lambda$ 乘以绝对值的减少量。若保留非零系数带来的拟合改善不足以抵消相应的惩罚增加，最优选择就可能是将它设为零。

平方惩罚则不同，越接近零，相同的系数绝对值减少所带来的惩罚减少就越少。反过来看，从零开始引入一个很小的非零系数，其平方惩罚增加得很慢；如果拟合误差的减少超过这部分代价，保留这个非零系数就更有利。因此，Lasso 可以把一部分系数直接压到零，而岭回归通常使系数变小，却不自动产生大量精确为零的系数。

当一部分系数为零，预测式只保留部分特征的贡献，这种参数中含有较多零值的情况称为稀疏。岭回归重在整体收缩，Lasso 还可能产生稀疏结果；并不是所有数据和强度都会使 Lasso 删除特征。

### 5.2 保留下来的特征说明了什么

如果某个特征的系数在 Lasso 中变为零，表示在当前数据、其他特征和惩罚强度下，拟合结果没有使用它的线性贡献。这不等于证明该特征在真实过程里没有作用。两个特征高度相似时，模型

可能只保留其中一个，换一批样本又可能保留另一个。

同样，保留的非零系数只说明模型在这个预测关系中使用了该特征，不能直接证明改变该特征就会造成标签变化。特征筛选服务于当前预测模型，因果解释需要其他证据。

### 5.3 分类可以保留交叉熵，再加入参数惩罚

T05 的逻辑回归以平均交叉熵 $L$ 为数据损失。正则化也可以用于这个目标，例如在本章的平方惩罚约定下写为：

$$L_\lambda = L + \frac{\lambda}{2}\sum_{j=1}^{d} w_j^2.$$

分类概率的计算方式没有因此改变，仍由线性分数经 Sigmoid 得到。但训练选择参数时，还要考虑参数惩罚，因此训练出的参数与概率可能改变。与 T05 只改阈值时概率不变的情形相比，这次约束发生在训练阶段。

软件接口对强度的命名和系数约定可能不同。B03 的分类模型使用 `C`，它对正则化强度作反向控制：其他设置不变时，较小的 `C` 表示较强的约束。不能把 `C` 的数值直接当作岭回归的 $\lambda$，也不在不同模型之间机械换算。实验固定 `C=1.0`，分类部分仍只观察两个阈值。

## 6. 从结果表选择候选并解释依据

第 3.2 节通过曲线观察了强度变化，本节回到 B03 原定的 $\lambda = 0, 0.1, 1$ 三个候选，用结果表完成一次具体选择。这份合成回归数据有 12 个不同量级的连续输入，编号和划分标记不进入模型，目标是连续响应。输入是抽象模拟测量，没有真实生产单位。

下表列出训练与验证 MAE，并增加系数 L2 范数。范数在标准化坐标下计算，它不是预测误差指标，而是用来检查参数整体收缩的参考。

| $\lambda$ | 训练 MAE | 验证 MAE | 系数 L2 范数 |
|---|---|---|---|
| 0 | 9.422 | 18.021 | 25.767 |
| 0.1 | 9.582 | 17.362 | 22.427 |
| 1 | 14.079 | 17.651 | 11.569 |

先明确选择标准：本次按验证 MAE 比较，数值越小越好。因此选择 $\lambda = 0.1$，其验证 MAE 为 17.362，低于另外两个候选。

再核对其他两列。最低训练 MAE 对应 $\lambda = 0$，最小系数范数对应 $\lambda = 1$，都不是本次选择。训练 MAE 说明对训练记录拟合得怎样，系数范数说明参数整体大小，验证 MAE 则提供模型在这批未参与拟合的验证对象上预测表现的比较依据。三列回答不同问题，不能互相代替。

实验比较采用 MAE，训练使用的却是平方误差加惩罚，两者不必是同一公式。带惩罚的目标用于确定每个候选的参数，MAE 用于在相同评价条件下比较预测误差。因此，也不能直接把不同强度下的训练目标值排在一起，以最小者代替验证选择。

这张表格支持的结论可以写成“在固定划分、训练内标准化和三个预设强度下，$\lambda = 0.1$ 的验证 MAE 最低，因此选择这个候选。”注意，这个范围限定很重要：第 3.2 节九个图示候选的最低点为 $\lambda = 0.3$，不影响这里的三候选比较，却说明本次选择不是对所有强度的最优证明。第 3.2 节和本节都用验证集比较候选，没有独立最终测试集，分数差距也没有经过统计显著性检验。

## 7. 本章小结：约束改变训练目标，验证支持选择

正则化在预测误差之外加入参数惩罚，使训练在拟合数据和限制参数之间作选择。岭回归采用平方惩罚，Lasso 采用绝对值惩罚；前者通常使系数收缩，后者还可能产生零系数。惩罚强度越大不等于模型越可靠，要结合训练与验证证据判断是否限制不足或过强。

参数大小与输入尺度有关。相同预测在不同单位下可以对应不同的系数，因此本次先从训练数据估计标准化变换，再在统一坐标上训练和计算惩罚。验证数据用于比较候选，不能反过来参与训练内变换的估计。

B03 将在固定划分下完成这些对照，并衔接 T05 的分类概率与阈值。T07 我们将讨论当一次划分的结果可能受样本选择影响时，怎样组织更系统的验证与有限候选选择。

## 8. 活动与实验查阅

### 8.1 用纸笔连接目标、强度和尺度

配套纸笔活动的 A 部分比较同一目标中的两种代价，可按第 2.3 节先计算系数平方和，再乘强度并加上训练误差。B 部分用固定验证表选方案，对应第 3 节。C 部分改变计量单位并判断标准化来源，对应第 4 节。活动可在相应概念讲解后穿插完成。

共同的核对顺序是先确认当前样本、坐标和计算标准，再比较结果。目标值改变时，检查究竟是预测误差、系数还是强度变了；验证分数改变时，则要确认评价对象与指标仍保持一致。

### 8.2 B03 的两段任务与数据对应

使用 B03 Notebook。第一段完成给定函数中的岭模型创建和训练调用，指标与系数范数计算已经提供。第二段运行给定分类模型，提取正类概率并完成阈值判断。全部任务在这一份 Notebook 中完成，数据、预处理和结果展示均有已有支持。

回归部分的 `X_train`、`X_val` 分别为 `(32, 12)`、`(48, 12)`，标签为 `(32,)`、`(48,)`。分类部分是另外的数据表，输入为计划负荷比例与开工前环境指数，训练与验证分别有 120、40 个样本。两段数据、目标和模型不同，应分别读取与处理，不能混用标准化器或标签。

`StandardScaler().fit(...)` 从训练特征估计逐列均值和标准差；随后对训练和验证调用同一个标准化器的 `transform(...)`。这一步改变输入坐标，不训练预测模型。`model.fit(...)` 才根据变换后的训练输入与标签确定预测参数，`model.predict(...)` 则使用已有模型产生预测。

### 8.3 理论强度与 Ridge 接口的对应

本章的岭目标为：

$$J_\lambda = \frac{1}{2n}\sum_i (\hat{y}_i - y_i)^2 + \frac{\lambda}{2}\sum_j w_j^2.$$

B03 使用的 `Ridge` 接口最小化平方误差之和加 `alpha` 倍系数平方和。把理论目标整体乘以 $2n$，得到：

$$2nJ_\lambda = \sum_i (\hat{y}_i - y_i)^2 + n\lambda\sum_j w_j^2.$$

因此，本次使用 `alpha=n_train * lam`，其中 `lam` 对应 $\lambda$，`n_train` 是训练样本数。两个目标只相差一个正常数，最优参数集合相同。比如另一份训练表有 10 个样本，采用 $\lambda = 0.2$ 时，接口参数应为 `alpha=2.0`。这项换算由本次目标定义和接口约定共同决定，不需要把它背成适用于所有库的通则。

程序已提供半均方误差、惩罚与目标值的计算。阅读结果表时，将 `half_MSE`、`penalty` 与 `objective` 分别对应到数据误差、参数代价与二者之和。比较不同强度仍依据验证 MAE，不能直接选 `objective` 最小的一行，因为各行惩罚强度不同。

### 8.4 从多列概率中找到正类

分类模型的 `predict_proba(...)` 返回二维概率表，每行对应一个样本，每列对应一个类别。类别顺序由模型的 `classes_` 给出，要先找到标签 1 对应的列，再选出一维正类概率，而不是把整张表或 `predict(...)` 的类别输出当成概率。

例如，若 `classes_` 为 `[0, 1]`，另一个三样本概率表为 `[[0.7, 0.3], [0.2, 0.8], [0.5, 0.5]]`，正类概率就是 `[0.3, 0.8, 0.5]`，形状从 `(3, 2)` 变为 `(3,)`。若类别列顺序不同，所选列也应随之改变。

把固定的一维概率分别交给两个阈值，得到各自的类别数组，再与同顺序的验证标签核对。阈值判断包含等号。实验检查会传入 Python 列表，因此函数中若要直接执行数组比较，应先用 `np.asarray(p)` 把输入转成 NumPy 数组。比如列表 `[0.2, 0.7]` 本身不能直接与一个小数作逐元素大小比较；转换后的数组则可以。

分类部分使用带 L2 正则化的库模型，固定 `C=1.0`。模型训练完成后，比较 0.5 和 0.3 两个阈值时只复用同一组概率，不重新训练，也不额外搜索 `C`。

### 8.5 解释与保存

先引用自己的结果回答：哪个强度的验证 MAE 最低，它是否也是训练 MAE 或系数范数最低的；标准化参数来自哪部分数据；分类阈值降低后 FP 与 FN 怎样变化。把结果与机制连接，比只写“正则化有效”或“阈值降低更好”提供了更具体的证据。

完成 TODO 后删除该处 `raise NotImplementedError(...)` 停止提示，保留检查代码。重启内核并运行全部，在本人 Notebook 中保留两段结果与三项解释，按教师要求保存、备份并提交这

一份文件。

## 9. 自查与迁移

先独立作答，再核对答案。计算可以保留分数。

1. 某模型训练 MAE 很低，验证 MAE 却明显较高。为什么这只能提示可能过拟合，而不能直接证明一定需要增大正则化强度?

2. 同一训练表上，方案 A 的训练半均方误差为 1、系数为 $[1,3]$；方案 B 的训练半均方误差为 2、系数为 $[1,0]$。分别在 $\lambda=0$ 与 $\lambda=0.5$ 下计算目标并比较。截距是否加入惩罚?

3. 同一划分和指标下，三个强度 0、0.2、2 的验证 MAE 分别为 6、4、5，系数范数分别为 10、7、2。应选哪个候选？为什么不能直接选范数最小者?

4. 同一关系写为 $\hat{y}=5x$，换单位后写为 $\hat{y}=0.5x'$，其中 $x'=10x$。预测是否相同？直接惩罚系数平方，惩罚相差多少倍?

5. 训练输入为 $[2,8]$，验证输入为 11。按总体标准差约定求训练均值、标准差和标准化后的三个值。若先对全表估计变换，验证数据参与了哪一步?

6. 岭回归的系数都很小，是否意味着模型已经删除所有对应特征？Lasso 留下一个非零系数，是否证明该特征是标签变化的原因?

7. 训练样本数为 20，理论目标采用本章约定，$\lambda=0.3$，`Ridge` 的 `alpha` 应是多少？若另一个模型使用 `C=0.3`，是否能宣称它采用了相同惩罚强度?

8. 分类模型已训练完毕，只把阈值从 0.5 改到 0.3，参数、正类概率、交叉熵和类别中哪些可能改变？这与改变正则化强度后重新训练有什么不同?

### 答案要点与回看位置

1. 训练与验证差距可能与过度适应有关，也可能受到数据分布变化、数据质量或流程问题影响。应先核对数据与训练过程，再在合理验证条件下比较有限候选；增大强度不保证改善。回看第 1.1—1.2、3.1—3.2 节。

2. 平方和分别为 10、1。$\lambda=0$ 时目标为 1、2，方案 A 较小；$\lambda=0.5$ 时，方案 A 为 $1+0.5\times10/2=3.5$，方案 B 为 $2+0.5\times1/2=2.25$，方案 B 较小。本章不惩罚截距。这个比较只涉及给定参数与训练目标，不证明验证最优。回看第 2.1—2.3 节。

3. 选择 $\lambda=0.2$，因为它在当前候选中的验证 MAE 最低。范数最小表示系数受约束较强，不表示预测误差最低；当前结果不保证其他数据仍选同一个强度。回看第 3.2、6 节。

4. 预测相同。平方分别为 25 和 0.25，固定强度下前者惩罚是后者的 100 倍。计量方式改变会影响原始系数惩罚，比较前应明确输入坐标。回看第 4.1 节。

5. 训练均值为 5、标准差为 3，训练坐标为 $[-1, 1]$，验证坐标为 2。先用全表估计会让验证输入参与均值和标准差的确定，并间接影响训练输入坐标。回看第 4.2—4.3 节。

6. 不意味着删除，只要系数非零，该特征仍可能参与预测。Lasso 的非零系数表示当前拟合使用了这个特征，不能自动解释为因果关系；零系数也不能证明现实中没有作用。回看第 5.1—5.2 节。

7. `alpha=20 * 0.3=6.0`。`C` 是另一个接口对强度的反向控制，目标和缩放约定也需要核对，不能仅凭相同小数认定强度相同。回看第 5.3、8.3 节。

8. 固定模型和输入，只改阈值时，参数、概率与交叉熵不变，类别可能改变，也可能没有样本跨过新旧阈值。改变正则化强度后重新训练，则改变了参数选择的目标，所得参数和概率都可能变化。回看第 3.3、5.3、8.4 节及 T05。