T07 交叉验证与模型选择

让数据轮流接受检查

机器学习课程学生讲义

辅修版 · 2026 年 10 月 31 日

学生讲义 · 辅修版。对应 T07（2 理论学时）；本章完成纸笔活动，在 T08 后的 B04 中使用交叉验证。

导读

T06 在同一训练集上拟合几个正则化强度不同的模型，再根据同一验证集上的误差作选择。这个安排使比较条件一致，但结果仍可能受到这一次划分的影响。如果验证部分恰好包含较容易预测的样本，分数可能较好；换一组记录，误差以及候选之间的排序都可能变化。我们希望利用多组训练与验证安排，观察一个候选在不同记录上的表现，而不只是依赖一次划分。

一个办法是把用于开发模型的数据分成几块，让各块依次承担验证任务。当某一块作为验证集时，该块数据不参与训练，只用其余块的数据训练模型。最后，把各块轮流作为验证集得到的验证结果汇总起来，再比较预先规定的候选。这种办法称为 K 折交叉验证，是交叉验证的一种常见形式。本章将说明各轮数据怎样分工、为什么填补缺失值和标准化也必须随训练部分重新拟合，以及选择完成后怎样准备实际使用的模型。

> 确定开发数据与比较规则 → 分块并轮流验证 → 每折重新拟合完整流程 → 汇总同条件分数 → 按汇总分数选择设置，并在全部开发数据上重新拟合。

完成本章后，你应该能画出多折交叉验证的训练与验证分工，计算平均分并限定比较结论，识别全表预处理造成的泄漏，说明每折训练得到的模型与最终重新拟合的模型有什么不同。

1. 从一次划分到多轮验证

1.1 分数反映模型，也反映参与评价的样本

仍以开工前预测批次能耗是否超限为例。预测输入是开工前已知的计划负荷比例和环境指数，标签是完工后取得的超限状态。两个候选在同一验证集上比较，因而能够避免评价对象不同造成的不公平。但是，这次验证只用了全部记录中的一部分。

如果其中接近类别边界的批次较多，两个候选的准确率可能都偏低；如果批次较容易区分，准确率又可能都较高。不仅分数本身会变化，两个候选之间的差距乃至排序也可能随验证样本改变。一

次验证提供了这批对象上的证据，却没有展示换一批对象后结果会怎样变化。因此，我们希望在几组预先安排的训练与验证划分下比较候选，观察其表现及差异是否一致。

多轮验证的目的就是把判断依据从单一的训练集与验证集扩展到多组训练与验证安排。这里的重点是事先安排好轮换顺序，让每个候选接受相同检查。如果不断尝试随机种子，最后只保留分数最好的一次，实际上等价于根据结果挑选评价条件，并没有把不同划分下的表现如实汇总，也就丧失了多轮验证的意义。

1.2 开发数据是一种用途

本章把用于训练、比较候选及调整方案的数据统称为开发集。这个名称强调数据参与了开发过程。在一次固定划分中，开发集可以再分为训练集和验证集；在交叉验证中，它又可以分成轮流承担训练与验证任务的几块。训练与验证的用途仍然存在，只是它们对应的记录随轮次变化。

如果已经事先留出独立最终测试数据，交叉验证通常在开发部分内部进行，测试数据继续保留。T02 对测试数据的要求仍成立：用来训练或选择方案的记录，不能同时为这个选择提供完全独立的最终检查。

在本单元的练习中，只使用标记为 `train` 的 120 行合成记录作为开发集。标为 `validation` 的另外 40 行记录本次不参与交叉验证。它们在此前练习中已经使用过，因此也不能因为本次暂时不用，就改称全新的独立测试集。文件中的标记记录了此前的安排，当前用途还要由实际流程判断。

2. 三折交叉验证怎样轮换

2.1 每一折都有自己的训练部分和验证部分

把开发集分成三个互不重叠的块 A、B、C，先用 B、C 训练，在 A 上验证；再用 A、C 训练，在 B 上验证；最后用 A、B 训练，在 C 上验证。把开发数据分为 K 块并作这种轮换，称为 K 折交叉验证；这里 $K = 3$，即三折交叉验证。下文把一次训练与对应验证的安排称为一折。

例如，一份九行小表分为 A=[1,2,3]、B=[4,5,6]、C=[7,8,9] 三块。数据的角色如下：

轮次	块 A	块 B	块 C	训练行数	验证行数
第 1 折	验证	训练	训练	6	3
第 2 折	训练	验证	训练	6	3
第 3 折	训练	训练	验证	6	3

每行恰好接受一次折内验证，并在另外两折参与训练。例如第 1 行在第 1 折参与验证、第 2、3 折参与训练，这本身符合轮换安排。要检查的是为第 1 折产生预测的那个模型，有没有在拟合时利用第 1 行的信息；第 2 折则要另外核对自己的训练范围。不能把不同轮次合并起来，要求一条记录永远只能承担一种角色。

2.2 轮换需要重新训练模型

第 1 折训练后，参数已经利用了 B、C 两块的标签，因此这个模型不能直接用于第 2、3 折的验证。正确做法是按相同候选设置重新创建模型，并在 A、C 两块上训练，再在 B 块上验证。

因此，一个候选经过三折交叉验证后，会得到三个分别训练的模型和三份验证分数。它们的模型形式和设置相同，参数却可能不同，因为每次用来确定参数的训练记录不同。交叉验证比较的对象是候选模型设置在这一训练与评价安排下的表现，而不是给某一个固定的模型重复打三次分。

本单元的 120 行开发数据分成三折，每折 80 行训练、40 行验证。这里的 40 行验证来自这 120 行内部，与第 1.2 节原先另留的 40 行不是同一批记录。三折完成后，120 行都曾接受折内验证。

2.3 分层保持类别比例，分组和时间约束另有作用

分类任务的数据如果某个标签的总数较少，完全随机分块可能使各块的类别比例差异较大。分层划分会尽量让各块保持接近整体的类别比例。例如，30 行中有 6 行超限，分成三块时可以尽量让每块分到 2 行超限。在这个例子中，每块都能包含两类对象，便于逐折检查分类表现；分层没有增加新样本，少数类样本不足时也不能保证每块都有该类别。

本单元假设合成批次相互独立，因此采用随机划分，并通过分层尽量保持各块的类别比例，组成三折交叉验证。若同一设备有很多行记录，而任务是预测从未见过的设备，就要按设备隔离；类别比例接近并不能保证设备已经分开。若目标是预测未来，则应让训练早于验证，并根据时间方向安排多轮检查。随机分成三块再轮换，不保证模拟未来预测的条件。

因此，划分方式要根据预测对象和实际使用情境决定。交叉验证给出了多轮检查的组织方法，并没有取消 T02 对对象关联和信息时点的要求。

3. 汇总分数并比较有限候选

3.1 每折分数与平均分回答什么

准确率表示参与评价的样本中判断正确的比例。本章计算的是每折验证部分的准确率，数值越大越好。设候选模型在第 k 折的准确率为 a_k，$k = 1, \ldots, K$。各折准确率的算术平均为：

$$\bar{a} = \frac{1}{K} \sum_{k=1}^{K} a_k.$$

$\bar{a}$ 表示折内验证的平均表现。本章各折验证样本数相同，因此这个均值也等于把每行在它接受验证时得到的判断汇总，计算全部判断的准确率。如果各折大小不同，直接平均会让每折权重相同，而不是让每条记录权重相同；解释结果时要说明采用哪种汇总方式。

下面是独立教学算例。三个验证块各有 20 行，两个候选共用相同的三折和准确率指标：

候选	第 1 折	第 2 折	第 3 折	平均准确率
A	0.70	0.85	0.75	
B	0.75	0.80	0.80	

对候选 A，$\bar{a}_A = (0.70 + 0.85 + 0.75)/3 \approx 0.7667$；对候选 B，$\bar{a}_B = (0.75 + 0.80 + 0.80)/3 \approx 0.7833$。若事先约定按平均准确率选择，则在这两个候选中选择 B。两者相差约 0.0167，即 1.67 个百分点。在这个例子中，这个差距意为 60 次折内验证判断中多判对 1 次。

这个计算提供了本次选择的依据，但仍然无法证明候选 B 对所有数据都表现更好。分数依然受到样本、划分以及可用训练量的影响；一次有限比较中的小幅优势，也不能直接当作已经经过统计检验的显著差异。

3.2 模型参数与候选设置的分工

T03—T05 中的系数与截距由训练确定，是模型参数。T06 中的正则化强度 λ 则是预先设置后，模型按该强度训练。这类控制模型或训练方式、通常在训练前设定的量称为超参数。本章以正则化强度为例，讨论怎样通过交叉验证选择超参数。注意实验接口的 `C` 虽然同样表示逻辑回归的正则化强度，但它与 λ 方向相反。

交叉验证中，每个候选对应一套事先规定的超参数设置。比如比较 $\lambda = 0.1$、$\lambda = 1$、$\lambda = 10$，每个设置都要在每一折中重新训练模型并计算验证分数，最后汇总三折结果。三个候选设置共需 $3 \times 3 = 9$ 次拟合。

所有候选设置应当使用统一的划分、输入和评价指标。否则，如果一个候选接受较容易的验证对象，另一个接受较困难的对象，均分的差距就混入了评价条件的差别。基线也需要接受相同检查，才能说明候选相对于简单基线改善了多少。

若候选均分相同，应采用事先规定的并列处理规则，例如保留候选列表中先出现的一项；这只是确定选择的约定，不表示它已被证明更优。

3.3 波动和搜索范围也是比较的一部分

只留下均分，会丢掉各折之间的差异。例如第 3.1 节中，候选 A 的三个分数变化较大，候选 B 更接近。这说明在本次三折验证中，候选 B 的准确率波动较小。为了保留这部分信息，可以记录每组设置在每一折的分数，并用标准差汇总它们围绕均值的波动。本章用下面的标准差描述各折分数围绕均值的波动：

$$s_{\text{fold}} = \sqrt{\frac{1}{K}\sum_{k=1}^{K}(a_k - \bar{a})^2}.$$

这里分母是 K，与之前的 `ddof=0` 一致，它描述当前这几折分数的离散程度。对第 3.1 节的分数计算，候选 A 的折间标准差约为 0.0624，候选 B 约为 0.0236。这与表中 B 的三个分数更接近的现象一致。

标准差较小意味着本次各折分数较接近，并不单独意味着模型更好。一个每折都预测很差的模型，也可能有很小的标准差。

这些折的训练部分彼此重叠，分数不是几次完全独立实验的结果。因此，不能直接把上述标准差解释为最终性能的置信区间，也不能仅凭两个均分相差几个标准差就宣布显著优胜。本章用它辅助读表，不要求进行统计检验。

候选范围也应事先限定。用交叉验证分数选择 λ，然后继续根据这些分数改特征、改阈值或加候选，仍然是在利用开发数据选择方案。尝试越多，就越可能找到恰好适应当前数据的设置。交叉验证扩展了检查的安排，最高均分却仍参与了选择，不能因它来自三折就视为完全独立的最终成绩。

4. 预处理也要在每折重新拟合

4.1 用训练数据确定缺失值的填补规则

在前面的章节中我们已经介绍过了标准化。在这里，我们再介绍一种常见的数据处理情景：字段缺失。字段缺失是指某一条记录的某个特征没有记录，但其他特征和标签仍可使用的情况。例如，某个批次的环境指数没有记录，但计划负荷比例和最终是否超限有完整记录。与 T01 中按任务所需列筛选完整记录不同，本章将介绍如何填补缺失值。

一种简单方法是用当前训练部分该特征非缺失值的中位数填补。中位数是把数值从小到大排列后位于中间的值；数值个数为偶数时，取中间两个数的平均。例如当前训练集的某特征为 `[2，6，缺失]`，非缺失值是 2、6，中位数为 4。把缺失项替换为 4，得到 `[2，6，4]`。

若验证部分的该特征为 `[20，缺失]`，就沿用训练部分确定的填充值 4，得到 `[20，4]`。验证数据接受的是已经学得的填补规则，不再根据自身数值另算中位数。

此外，要注意的是填补并不是恢复了缺失的记录，而是采用了某种规则替代。它是否有助于预测，要与整条建模流程一起验证，不能仅凭表格里不再有空值就判断信息已经完整。

4.2 先处理全表，为什么会影响折内验证

沿用第 4.1 节的例子，当前训练列为 `[2，6，缺失]`，验证列为 `[20，缺失]`。只根据训练记录确定的填充值为 4。如果先把两部分合并，非缺失值就成为 `[2，6，20]`，中位数变为 6。训练行中的缺失项也随之由 4 变成 6。

这意味着，验证记录中的输入值 20 不只是等待模型预测，它已经通过填补值改变了训练输入。即使没有读取验证标签，最终训练得到的参数也可能受到这条验证记录的影响。因此，验证与训练之间需要隔离的不只有标签，还有用来确定数据处理规则的输入信息。

标准化也会产生这样的影响。假如把训练和验证记录合在一起估计均值，某条较大的验证值就可能拉高这个均值，改变所有训练记录变换后的坐标。模型随后在这些坐标上学习，因此验证记录同样间接影响了参数。把记录分开以后再训练最后的模型，不能消除此前处理已经带来的影响。

所以，每折都应从原始输入开始，只根据当轮训练部分确定填补值和标准化参数，再训练模型。验证部分接受的是这套已经确定的处理与预测规则。换到下一折时，训练记录改变，整套规则也要重新确定。

4.3 学习得到的是一套处理与预测规则

一个新批次的环境指数可能恰好缺失。要对它作预测，我们既需要分类模型，也需要知道用什么数填补缺失项，以及怎样把输入变成模型训练时使用的坐标。只有模型系数，却没有此前确定的填补值、均值和标准差，还不足以重现原来的预测过程。

因此，在本章的例子中，一套学得的规则包含三个相连的部分：用训练数据确定的中位数填补输入，用填补后的训练数据确定的均值和标准差变换坐标，再用变换后的输入和训练标签确定分类参数。前一步的输出成为后一步的输入，它们共同决定一个原始批次怎样得到预测。

这也解释了交叉验证为什么要重新拟合整个过程。第 1 折留下块 A，就应只根据 B、C 确定上述规则；第 2 折留下块 B，则只根据 A、C 重新确定。验证对象虽然换了，检查的问题始终相同：当这套方法还没有接触当前留出记录时，它能预测得怎样？

这里区分了需要从数据中学习的处理与事先固定的处理。例如，把所有记录的产量从“件”换成“百件”，若只是统一除以 100，并未从验证数据估计任何数值，就不因执行在分折前而产生上述泄漏。需要逐折重新确定的，是中位数、均值、标准差等由数据估计的规则。

5. 选择以后，在全部开发数据上重新拟合

5.1 选择的是设置，重新训练得到可用模型

交叉验证完成后，每个候选留下三组模型参数和三个验证分数。以正则化为例，选中某个 λ，表示我们决定采用这个强度训练最终模型，并没有同时决定采用哪一折的具体参数。

为什么不直接取验证分数最高那一折的模型？因为那一折只根据部分开发记录训练，而它的较高分数也可能与当折验证对象较容易有关。这个分数说明该次训练与验证的结果，并不能证明这组参数比另外两折更适合实际使用。况且，选择完成后，还有一部分开发记录可以参与训练，却没有被那个折模型利用。

因此，先保留选定的模型形式、特征和正则化强度，再用全部开发集重新训练。对本章的 120 行开发集而言，三折比较时每个模型训练 80 行；选择后重新训练的模型则利用全部 120 行。中位数填补和标准化也重新估计，与最后的模型一起形成一套可以应用于新批次的规则。

原先在某折接受验证的行，此时可以参与训练，并不矛盾：交叉验证阶段留出它，是为了取得这一折的比较证据；选择完成后使用它，是为了在既定设置下充分利用开发资料。数据用途随阶段改变，已有分数的含义却仍然由它当时的取得过程决定。

5.2 新训练出的模型还没有新的评价成绩

在全部开发数据上重新训练，得到的是一个新的模型。它使用的训练记录比每个折模型更多，参数也可能不同。因此，前面的平均验证分数并不是直接对这个新模型测量出来的成绩。

还要注意，候选的平均分已经影响了选择。假如某个设置恰好更适应当前开发记录，它就更可能被选中；拿这个最高分同时证明选择有效，会使评价偏向那些已经帮助我们作出选择的数据。多轮验证提供了比较依据，但没有把用于选择的数据变成独立于选择的新证据。

若事先保留了未参与训练与选择的测试数据，就可以在设置确定并重新训练后，用它评价最终模型。若没有这样的数据，现有结果仍可用于说明选择依据，但最终模型在独立数据上表现怎样，仍是待回答的问题。用更多开发数据训练与取得新的独立评价，是两个不同的步骤。

6. 结合基线理解选择的意义

6.1 胜过另一个候选后，还要与简单基线比较

第 3.1 节中，候选 B 的平均准确率约为 0.7833，高于 A 的 0.7667。这告诉我们两个候选之间怎样选择，却还没有说明它们相对简单基线改善了多少。T01 引入的多数类基线仍然可以作为比较起点：每一折只根据该折训练部分的标签确定多数类别，再对验证对象都预测这个类别。

在交叉验证中，基线也要逐折确定。第 1 折的多数类别来自 B、C 的训练标签，第 2 折来自 A、C，第 3 折来自 A、B。即使三次恰好都选中同一个类别，它们也分别具有各自的训练依据。若先用全部开发标签确定多数类别，那么每折留出的标签已经参与了预测规则的形成。

继续第 3.1 节的教学算例，假设多数类基线在相同三折上的准确率分别为 0.60、0.55、0.65，均分为：

$$\bar{a}_{\text{baseline}} = \frac{0.60 + 0.55 + 0.65}{3} = 0.60.$$

候选 B 比这个基线高约 0.1833，即 18.33 个百分点。于是，我们不仅知道 B 的均分略高于 A，也知道在当前验证安排下，它比始终预测训练多数类的规则判对了更多对象。两种比较提供的信息不同：前者帮助在候选之间选择，后者说明相对简单起点的改善。

6.2 让结论对应已经回答的问题

依据以上算例，可以作出这样的结论：“在相同三折和准确率指标下，候选 B 的平均验证准确率约为 0.7833，高于候选 A 和多数类基线。因此选择 B 的设置，并在全部开发数据上重新训练。”这里把比较条件、数值依据和后续动作连在了一起。

这个结论没有回答最终重新训练的模型能否在未来设备、其他生产条件或独立测试资料上保持同样表现。要回答那些问题，需要与使用情境对应的新检查。交叉验证使我们能够更充分地利用现有开发记录作比较，它并没有为尚未观察到的情境自动提供结果。

评价指标也决定了我们回答的是哪个问题。准确率汇总所有正确判断；如果实际任务特别关心漏掉超限的后果，就应在比较前考虑召回率、精确率或误判代价。先明确要比较的错误，再组织验证，才能让选择服务于任务，而不是因为某个数字较大就临时改变问题。

7. 本章小结：轮换数据，比较学习方法

交叉验证通过轮换训练与验证记录，检查一个候选设置在不同训练与验证安排下的表现。每一折都重新训练，所以得到的是分别训练的模型；汇总后的分数用于比较相同条件下的候选设置。

从训练数据估计的填补值、均值和标准差，与模型系数一起影响预测。因此，验证需要覆盖整套规则的学习过程，而不仅是最后得到的模型。每折只从当轮训练部分确定规则，验证部分再使用它们，才能检查方法面对留出记录时的表现。

选定模型形式和超参数以后，用全部开发集重新训练，得到可用于预测新对象的最终模型。用于选择的交叉验证分数仍保留其原有含义，独立最终评价需要另有依据。

8. 活动与实验查阅

8.1 用纸笔追踪轮换与拟合范围

配套纸笔活动的 A 部分可按第 2 节先画角色表，再核对每折训练与验证记录。B 部分按第 3 节计算均分，并说明它用于哪一范围的选择。数值以活动自己的题干为准。

C 部分先从当前训练非缺失值计算中位数，再检查验证输入是否提前影响这个值，对应第 4 节。活动可以随概念讲解穿插完成，不需要运行程序。

8.2 为 B04 准备一条可解释的验证流程

本章先通过纸笔理解谁参与当折拟合、谁只接受当折预测。学习 T08 后，使用 B04 中提供的预处理与交叉验证骨架，把这套安排用于少量树深度候选。现在需要能够读出每折的训练和验证用途，并解释为什么填补值必须来自当折训练部分，不需要提前理解树的划分算法。

回看程序时，可以依次核对三件事：交叉验证接收到的是否是未在全表上拟合过预处理的输入；每个候选是否共用相同折与指标；选定设置后是否重新拟合完整流程。具体数据、接口与提交要求将在 B04 Notebook 中就地提供。本章纸笔答案用于理解与复习，不另增一份实验提交。

9. 自查与迁移

先独立作答，再核对答案。可保留分数或将小数保留四位。

1. 一份 18 行开发数据平均分成三块。每折分别用多少行训练、多少行验证？某行在第 1 折训练、第 2 折验证，是否本身就是泄漏？

2. 三个等大小验证块上的准确率：候选 A 为 `[0.8,0.6,1.0]`，候选 B 为 `[0.8,0.8,0.8]`。按均分能否唯一确定优胜者？更小的折间波动是否证明普遍更好？

3. 某列当前训练值为 `[2,8, 缺失]`，当前验证值为 `[30, 缺失]`。分别求训练中位数和把两部分合并后求得的中位数，解释应该使用哪个值填补验证缺失。

4. 一名同学在全部开发数据上先拟合标准化器，再把处理后的输入交给三折交叉验证。模型本身每折重新训练，为什么仍没有满足本章的隔离安排？

5. 比较 4 个预设候选，每个都用相同三折，一共需要多少次候选拟合？选定后应取最高分那一折的模型，还是在全部开发数据上重新拟合？

6. 同一设备有多行记录，任务是预测从未见过的设备。分层三折让各折超限比例相近，是否足以满足任务？

7. 按第 3.1 节的均分选择候选 B 后，能否把约 0.7833 写成重新拟合模型的独立测试准确率？原先另留的 40 行此前已经看过，本次没用，是否因此恢复了独立性？

8. 在每折训练记录确定多数类的基线，与先在全部开发标签上确定多数类再进入各折，有什么区别？为什么候选应与基线共用验证折？

答案要点与回看位置

1. 每折 12 行训练、6 行验证。同一行跨轮次换角色是正常轮换，关键是对它作验证预测的那一折，没有利用它拟合预处理或模型。回看第 2.1—2.2 节。

2. 两个均分都是 0.8，按均分无法唯一确定；应遵守事先约定的并列处理规则，而不是看完结果后临时改标准。B 在当前三折无分数波动，只说明这三个汇总值相同，不证明它对其他数据普遍更好。回看第 3.1—3.3 节。

3. 训练中位数为 $(2+8)/2=5$；合并非缺失值 `[2,8,30]` 后中位数为 8。验证缺失应填 5，由当前训练部分确定。用 8 会使验证输入 30 提前影响训练与预测规则。回看第 4.1—4.2 节。

4. 验证特征已经影响全表均值和标准差，进而影响模型训练时使用的坐标。每折重新训练最后的模型无法撤销这一步；应让填补、标准化和模型在每折只根据训练部分重新确定。回看第 4.2—4.3 节。

5. $4\times3=12$ 次候选拟合，不含基线或最后重新拟合。确定设置后，用全部开发数据重新拟合完整流程，以利用可用于训练的记录；不根据某折最高分另外挑参数。回看第 3.2、5.1 节。

6. 不足。类别比例与设备身份是不同条件；应按设备分组，使评价中的新设备未在相应训练部分出现。分层不能替代这种对象隔离。回看第 2.3 节。

7. 不能。该均分来自交叉验证中的折模型并参与了选择，最终重新拟合也没有产生新测试证据。旧记录此前已经参与过开发过程，不会因为本次暂时不用就重新变成未参与开发的独立数据。回看第 1.2、5.2、6.2 节。

8. 每折的多数类是该折训练标签确定的规则；全表多数类会利用当折验证标签，改变隔离条件。共用折才能让候选与基线接受相同对象的检查，分数差才有一致的比较依据。回看第 3.2、6.1 节。