T08 决策树

从条件判断到数据划分

机器学习课程学生讲义

辅修版 · 2026 年 10 月 31 日

学生讲义 · 辅修版。对应 T08（2 理论学时），之后完成 B04（2 实验学时）。

导读

T05 介绍的分类任务的逻辑回归方法首先把输入特征转换为一个分数，再将这个分数转换为概率，最后根据概率做出类别判断。本章将介绍分类任务的另一类方法：先根据某个特征把对象分为两组，再在各组内部继续提问，直到能够给出类别。例如，先判断计划负荷是否超过一个界限，再对其中一组检查环境指数，最后判断类别。这些前后相接的条件可以画成一棵树，称为决策树。

决策树的条件规则很好理解，困难的是怎样从训练数据中确定它们。该先检查哪个特征，界限放在哪里，分几次才合适？本章将从一个只有六条记录的分类例子出发，解释怎样比较一次划分的效果，再讨论为什么训练记录分得更细，并不保证新对象也能预测得更准。

> 用条件把训练样本分组 → 衡量组内类别混杂程度 → 比较并选取一次划分 → 在子组中继续学习 → 用验证结果选择合适的深度。

完成本章后，你应该能沿树路径计算预测，手算一次基尼（Gini）不纯度及划分后的下降量，区分分裂阈值与概率阈值，解释叶内类别比例的含义。

1. 用一连串条件组织预测

1.1 从一个判断走到下一个判断

仍以开工前预测批次能耗是否超限为例。输入来自开工前已知的资料，正常编码为 0，超限编码为 1。设其中一个数值特征为 x，可以提出条件 “$x \le 2.5$”：满足条件的对象进入左边，不满足的进入右边。如果一边还有必要细分，就在这一边继续提出条件。

每个提出条件的位置称为分裂节点，也称内部节点。从分裂节点引出的两种去向称为分支。最开始接收全部输入的位置称为根节点。不再向下分裂、直接给出预测的位置称为叶节点。从根节点开始，根据一个对象的特征逐个回答条件，最后到达一个叶节点，就完成了这次预测。

例如，一棵只分裂一次的树可以规定：$x \le 2.5$ 时预测正常，否则预测超限。本课程约定，条件

成立时走左分支，不成立时走右分支。给定 $x=2$，满足 $x\le 2.5$，走向左叶并输出 0；给定 $x=5$，不满足 $x\le 2.5$，走向右叶并输出 1。

1.2 一条路径表达一组同时成立的条件

决策树的不同分裂节点可以使用不同的特征作为分裂条件。例如，先判断计划负荷是否较高，再在高负荷分支判断环境指数是否较高。要注意的是，标准决策树的每一次分裂通常基于单个特征。此外，到达某个叶节点，意味着对象满足这条路径上的全部分支要求。不同分支还可以检查不同特征，因此不同对象到达叶节点时，所经过的问题未必相同。

与将各特征加权形成一个分数相比，决策树通过多次分裂把输入空间分成若干区域，同一区域内的对象使用相同的叶节点预测。输入小幅改变时，如果仍沿原路径到达同一叶节点，预测就不变；如果跨过分裂界限，则可能到达另一个叶节点，预测也可能改变。

与逻辑回归方法类似的是，预测时只需要对象的输入，真实类别用于训练时比较划分、确定叶节点输出，或在预测后评价结果，不会成为新对象沿路径行走时必须知道的答案。

2. 怎样判断一组样本是否容易给出类别

2.1 用类别比例描述节点的不纯度

为了从数据学习分裂条件，需要衡量分裂后两个节点的特性。假如一个节点内的训练样本全部是正常批次，用正常作为这一组的预测，准确率就是 100%。如果正常与超限各占一半，无论统一输出哪个类别，都会错掉其中一半。我们称前一种节点为纯节点，后一种节点为不纯节点。

不纯节点显然也有区别。例如 99 个正常批次和 1 个超限批次组成的不纯节点，明显和 50 个正常批次和 50 个超限批次组成的不纯节点不同。为了衡量这种差别，我们引入了基尼（Gini）不纯度的概念。设当前节点中两类的样本比例分别为 p_0 和 p_1，则：

$$G=1-p_0^2-p_1^2.$$

这里 p_0、p_1 由当前节点的训练标签计数得到，且 $p_0+p_1=1$。对于纯节点，两个比例为 1 和 0，得到 $G=0$。对于 99 个正常、1 个超限的节点，$G=1-0.99^2-0.01^2=0.0198$，对于两类批次各占一半的不纯节点，$G=1-0.5^2-0.5^2=0.5$。在二分类中，Gini 介于 0 与 0.5 之间；越小表示类别越集中。

对于二分类任务，这个公式可以化简为 $G=2p_0p_1$。这个简化公式的概率意义是如果从当前节点中有放回的随机抽取两个批次，两个批次类别不同的概率 $p_0p_1+p_1p_0=G$。这为二分类的 Gini 不纯度提供了一种直观解释。注意，它不是这个叶节点采用多数类预测时的误判率，后者应由实际预测规则另行计算。

2.2 划分后的总体混杂需要按样本数加权

一次分裂把父节点分成左右两个子节点。设父节点共有 n 个训练样本，左右分别有 n_L、n_R 个，且 $n_L+n_R=n$；它们的 Gini 分别为 G_L、G_R。划分后的加权不纯度为：

$$G_{\text{split}} = \frac{n_L}{n} G_L + \frac{n_R}{n} G_R.$$

两个权重表示父节点中有多大比例的样本进入各组。若随机取一条父节点中的记录，它更可能进入样本多的子节点，所以那个节点的混杂也应在整体比较中占更大比重。

例如，左节点是有 2 个样本的纯节点，右节点有 4 个样本且 Gini 为 0.375。等权平均会得到 $(0 + 0.375)/2 = 0.1875$，而按样本数加权则得到 $(2/6) \times 0 + (4/6) \times 0.375 = 0.25$。两者不同，是因为前者将两个节点的权重视为相同，而后者按实际样本数赋权。由于三分之二的样本实际在右节点，不应只让它承担一半权重，因此应选择按样本数加权的结果。

设父节点的 Gini 为 G_{parent}，本次划分带来的不纯度下降为：

$$\Delta G = G_{\text{parent}} - G_{\text{split}}.$$

对同一个父节点比较不同划分时，父节点的值固定。因此，选择加权不纯度较小的划分，就等价于选择下降量较大的划分。

3. 从六条记录学出一次划分

3.1 比较两个候选阈值

下面六条记录是抽象教学样本，x 是一个数值特征，没有具体含义，只用于观察树的学习过程。

样本	A	B	C	D	E	F
特征 x	1	2	3	4	5	6
标签 y	0	0	1	1	0	1

根节点包含六个样本，正常与超限各 3 个，因此 $p_0 = p_1 = 1/2$，根节点的 Gini 为 0.5。先比较 2.5 与 3.5 两个阈值，假设分裂条件为特征小于等于阈值，因而小于等于阈值的样本进入左分支，大于阈值的样本进入右分支。

阈值为 2.5 时，左组标签为 `[0,0]`，所以 $G_L = 0$。右组标签为 `[1,1,0,1]`，正常占 1/4，超限占 3/4，因此：

$$G_R = 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = \frac{3}{8} = 0.375.$$

加权后得到：

$$G_{\text{split}} = \frac{2}{6} \times 0 + \frac{4}{6} \times \frac{3}{8} = \frac{1}{4}, \qquad \Delta G = \frac{1}{2} - \frac{1}{4} = \frac{1}{4}.$$

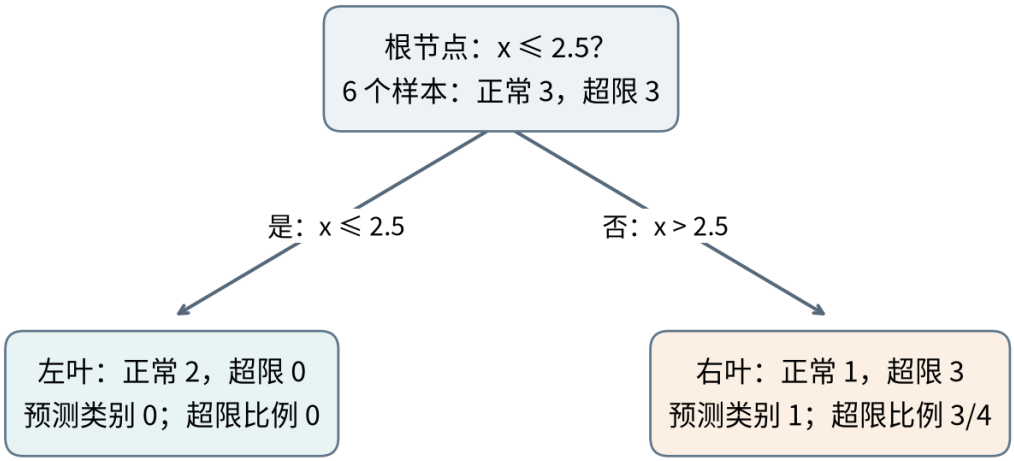
阈值为 3.5 时，左组标签为 `[0,0,1]`，右组为 `[1,0,1]`。两组的类别比例都是 1/3 与 2/3，只是多数类别相反，所以两边 Gini 都为：

$$1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}.$$

左右各占一半样本，加权不纯度也是 $4/9$，下降量为 $1/2 - 4/9 = 1/18$。在这两个候选中，阈值 2.5 的加权不纯度更低，因而选择 2.5 作为分裂阈值。

3.2 分裂以后怎样给出预测

如果只允许根节点分裂一次，左右子节点就成为叶节点。叶节点按其中训练标签的多数类给出预测：左叶全部为 0，预测正常；右叶四条记录中有三条为 1，预测超限。



六条训练记录经过一次分裂后形成的浅树

对 $x = 2$，沿左分支到达正常叶，预测为 0；对 $x = 5$，沿右分支到达超限叶，预测为 1。样本 E 的 $x = 5$、实际标签却是 0，因此它在这棵树中被误判。叶节点给一组对象相同预测，并不意味着组内每个训练样本都与多数类别一致。

左右叶共判对 5 条、判错 1 条，训练准确率为 5/6。这个数与划分后的加权 Gini 为 1/4 并不矛盾：准确率检查多数类输出判对多少，而 Gini 描述组内类别混杂，它们是两个不同的指标。

右叶的正类比例为 3/4，可作为该叶的正类概率估计；左叶的估计为 0。它们来自到达该叶的训练标签频率，而 T05 的逻辑回归通过线性分数与 Sigmoid 得到概率。一个新对象到达右叶，也会得到 0.75 的估计，但这四条训练记录不足以证明其真实超限风险恰好为 75%。两种方法的概率估计都需要用适当数据检查。

3.3 分裂阈值与分类阈值是两种界限

这里的 2.5 与特征 x 具有相同单位，决定对象往树的哪一边走。T05 的分类阈值则作用于已经得到的正类概率，决定最终输出哪个类别。前者划分输入，后者把概率变成类别。

例如，$x = 2.5$ 按本章约定走左边；到达右叶的对象都得到正类概率 0.75，若再按概率阈值 0.5 判断，则都输出 1。如果改用概率阈值 0.8，右叶对象会输出 0，但树中的 2.5 分裂界限没有改变。本章用叶节点多数类作基本分类规则，不另外搜索概率阈值；若叶内两类计数相同，需要按事先约定的规则处理并列。

4. 从一次分裂长成一棵树

4.1 在子节点内部继续寻找划分

根节点分裂后，如果其中某个子节点仍然不纯，就可以在该节点内部继续寻找划分，再分别检查产生的新子节点。有多个特征时，每次选择还要比较使用哪个特征，不同分支未必使用同一特征分裂。

不纯节点也未必还能继续分开。例如，两条记录的所有输入完全相同、标签却不同，依据这些输入的条件就无法将它们区分；此时仍需由叶节点给出预测。

数值阈值可以在相邻不同训练取值之间寻找。第 3 节排序后的输入为 1、2、3、4、5、6，2 与 3 之间的 2.5 就是一种候选。在这个没有缺失的小例子中，把阈值放在 2 与 3 之间的其他位置，会对已有记录产生相同分组；取相邻取值的中点，只是表达这种分组的一种方便方式。但对未来落在两者之间的输入，具体界限仍会影响去向。

这样的训练采取逐步选择：先确定当前节点最有利的一步，再在子节点继续。这称为贪心划分。它没有同时比较所有可能的完整树形，所以当前下降量最大的一步，不保证最终得到所有树中最优的一棵。

4.2 深度决定允许连续提问多少次

根节点的深度记为 0，每经过一条分支深度加 1。树的深度是最深叶节点的深度。因此，最大深度为 1 时，最多只允许根节点分裂，预测最多需要回答一个条件。最大深度为 3 时，一条路径最多经过三次条件判断。最大深度是允许的上限，不要求每条路径都长到这个上限。

第 3 节例子中的左叶已经是纯节点，不必再分；右叶仍有一个正常样本混在三个超限样本中。如果继续在右叶内部按 $x \le 4.5$ 分裂，左分支的 $x = 3, 4$ 均为超限，右分支的 $x = 5, 6$ 一正常一超限。再把后一组按 $x \le 5.5$ 分开，就可以在深度 3 内把六条训练记录全部正确判断。此时 $x = 5$ 不再与三个超限样本共用一个叶节点，而是独占一个正常叶。

这展示了增加深度怎样降低训练错误：树可以用更多条件区分原先共用一个输出的记录。它也提出一个问题：围绕 $x = 5$ 建立的狭小正常区域，反映的是能够用于新对象的关系，还是这条训练记录的偶然特点？只用这六条记录无法回答这个问题。

4.3 小叶节点为什么容易受个别记录影响

第 3 节右叶有 4 个样本，只改变其中一条记录的标签，正类比例的变化幅度为 1/4；左叶只有 2 个样本，同样的改动会使正类比例变化 1/2。可以看到，节点样本越少，其比例和多数类判断通常越容易受个别记录影响。

因此，限制复杂度不仅可以限制深度，还可以要求每个叶节点至少有一定数量的训练样本。若最小叶样本数为 2，就不允许通过一次划分产生只有一个样本的叶，第 4.2 节最后隔离 $x = 5$ 的分裂便不再允许。这个限制直接作用于样本分组，与 T06 对线性系数加入惩罚的方式不同，但思路类似，都是在约束对训练细节的适应。

另一种思路是先长出较大的树，再根据既定标准删去部分分支，让原先更细的区域重新合并。这

是后剪枝的基本思想。本章用最大深度和最小叶样本数控制拟合，不展开完整剪枝算法。

5. 深度怎样影响新样本的预测

5.1 用训练与验证表现判断约束是否合适

浅树能够表达的条件组合有限，可能把本来需要区分的对象放在同一叶中，训练与验证表现都受到限制。深树可以形成更多、更小的区域，训练分数可能提高，但对少数记录的偶然特点也可能更敏感。这个变化对应 T06 提到的欠拟合与过拟合问题，区别是现在调节的是条件划分的细致程度。

下面是另一份数据上的假设比较，不是第 3 节六行小表的结果，也不是实验输出。几个候选共用相同三折和准确率指标：

最大深度	平均训练准确率	平均折内验证准确率
1	0.75	0.70
3	0.90	0.80
6	1.00	0.72

深度从 1 增加到 3，训练与验证分数都提高，说明在本次数据上，较灵活的划分带来了改善。继续增加到 6，训练全部判对，验证却降到 0.72，提示新增的细分可能过分适应了训练细节，未改善验证记录的预测。如果预先约定按平均验证准确率选择，就选择深度 3，而不是训练满分的深度 6。

这个表格不表示中等深度总会胜出。如果数据中有用关系很简单，浅树可能已经足够；若关系需要较多条件才能表达，较深树也可能取得更好的验证结果。深度选择需要结合当前数据和评价安排。

5.2 为什么决策树通常不需要对输入进行标准化

对本章这样的数值树，每次分裂根据某个特征值是否超过阈值，将样本分到两边。例如，用米表示输入时的 $x \le 2.5$，换成厘米后就是 $x' \le 250$。每条记录进入哪一边没有变化，各子节点的类别计数与 Gini 也不变。

这与 T06 的系数惩罚不同：相同预测在不同单位下会改变线性系数大小，进而改变惩罚；树的阈值则随计量单位一起换算，训练记录的候选分组保持一致。因此，对本章按单个数值特征阈值划分的树，一般不需要通过标准化平衡各特征的数值量级。

对于缺失值，本章采用 T07 的中位数填补，并在每折训练部分估计填补值，再应用于该折验证部分。省去标准化与省去需要学习的填补规则，是两件不同的事。

5.3 沿用交叉验证选择整套方法

将几个预定深度分别放入相同交叉验证安排，每折重新确定填补值并训练树，再比较平均验证准确率。训练准确率用于观察拟合情况，验证均分用于选择深度；并列时可以事先约定选择较浅的树，以偏向更简单的模型。

确定深度后，再在全部开发数据上重新拟合填补与树。这样既利用了全部开发记录，也保留了 T07 中“用交叉验证比较设置”与“在全部开发集上取得最终模型”的区分。用于选择的交叉验证分数仍不是独立最终测试结果。

树的一条路径可以告诉我们模型用了哪些条件作判断，但不能单凭这些条件证明实际生产中的因果机制。例如，某个环境指数较高的分支中超限较多，可能反映关联或其他共同因素；树把它用作预测条件，不等于已经证明改变环境指数就能按同样幅度降低超限。

6. 本章小结：训练学出划分，验证选择复杂度

决策树把输入按条件逐步分组，沿路径到达叶节点后给出类别或类别比例。训练时用标签计算节点的 Gini，不同划分的效果按子节点样本数加权比较，再在子节点中继续选择。叶节点多数类输出和 Gini 描述不同方面，叶内比例可以作为该叶的概率估计，但是否可靠仍需用适当数据检查。

增加深度可以允许更细的划分，但小叶更容易受个别记录影响。最大深度与最小叶样本数限制这种细分能力，合适程度由同条件验证判断。树的数值划分一般不依赖标准化，填补等从数据学习的处理仍要遵守折内隔离。

B04 将把这些概念用于有限深度比较，并开始规划另一个质量不合格预测任务。后续 T09—T10 将讨论怎样组合多棵树形成集成模型，本章先理解一棵树怎样学习和预测。

7. 活动与实验查阅

7.1 用纸笔连起划分、预测与深度

配套纸笔活动的 A 部分对应第 2、3 节，先写子组标签，再计数、计算比例及加权 Gini。B 部分沿同一棵浅树预测，对应第 3.2—3.3 节。C 部分根据训练与验证表判断深度，对应第 5 节。活动可随相应概念穿插完成。

7.2 B04 的三项实现

使用 B04 Notebook。程序提供数据读取、填补、共同三折、绘图与结果汇总。三个待完成位置分别是：把函数收到的深度传给树、补全交叉验证调用、按验证均分选择深度。固定候选为 1、3、5，不增加搜索范围。

`build_tree(depth)` 返回一条“中位数填补 → 决策树”的流程。`DecisionTreeClassifier` 中的 `max_depth` 对应第 4.2 节的最大深度；`min_samples_leaf=2` 表示每叶至少两个训练样本，`criterion="gini"` 指定划分标准，`random_state=42` 固定随机性以方便复现。这里只把 `depth` 交给深度设置，其他配置已有支持。

在 `run_cv(depth)` 内，先用 `build_tree(depth)` 构造尚未拟合的完整流程，再将流程、原始开发输入 `X`、标签 `y` 和共同 `folds` 传给 `cross_validate`。接口返回的 `test_score` 是折内验证准确率，`train_score` 则用于诊断拟合；两者的平均值在结果表中分别记为 `validation_mean`、`train_mean`。选择前者最大的一项，并列时选较浅者，不能选训练均分最大的一项代替。

7.3 数据、结果与树图的对应

课堂数据含 120 行开发记录，输入仍为计划负荷比例与环境指数，带少量模拟缺失。开发输入为 `(120, 2)`，标签为 `(120,)`，每折 80 行训练、40 行验证。原先另留且已使用过的 40 行本次不评价。编号和原划分标记用于识别记录，不进入树的特征。

检查填补参数时，应与当前折训练行的逐列中位数对应。最后在全部开发数据重新拟合后，填补器才应使用全部 120 行。图中显示的则是最后重新拟合的树，不能把它的根节点样本数误当成某折训练数。

程序为控制图幅，只画所选树的前三层；若原树更深，图中省略号表示还有后续分支，不能当作完整叶节点。读图时先确认是否截断，再沿一条路径解释条件和去向，不要求抄写整棵树。

7.4 参考结果怎样帮助核对

下表是固定数据在参考深度 1、3、5 下的实际结果，与第 5.1 节的假设表不同。它用于检查结果的来源，不是要求所有运行都必须得到同一最佳深度。

最大深度	平均训练准确率	平均折内验证准确率
1	0.7708	0.7083
3	0.8292	0.6833
5	0.9083	0.6333

本次参考列表中，验证均分最高的反而是最浅的深度 1 候选；深度 5 的训练分数最高，验证分数却最低。这说明第 5 节中的选择方法可以迁移，假设表中的“选深度 3”却不能作为所有数据的预定答案。这里只能报告当前候选与三折下的比较，不宣称树比此前逻辑回归普遍更好。

完成 TODO 后删除相应的 `raise NotImplementedError(...)` 停止提示，保留检查代码。在本人 Notebook 中填写实际结果和三项个人解释，重启内核运行全部，注明辅助工具用途，保存至非保护盘并另留副本，按教师要求提交这一份实验文件。

7.5 综合任务从问题与评价计划开始

另一个新的合成任务是在生产批次开工前，根据已确定的计划负荷、温度设置与材料评分，预测完工后是否质量不合格。它的输入、标签和数据均与课堂超限例子不同，不能把两项任务的准确率直接比较。

使用持续项目 Notebook，本次只填写问题与计划：写清预测时点、对象、合法输入、一个简单基线、主要指标及划分理由，不要求立即训练项目模型。现有开发记录假设批次独立，可以在这个前提下考虑固定验证或分层交叉验证；缺失处理要与所选评价安排一致。

项目的最终评价资料由教师另行保留，不用于本次选择。计划会在后续阶段继续完善，沿用同一份项目 Notebook，不另增一份长报告，也不把计划草稿当作最终模型成果。

8. 自查与迁移

先独立作答，再核对答案。计算可以保留分数。

1. 某节点的两类训练标签比例为 1/4、3/4，Gini 是多少？若统一预测多数类，训练误判率又是多少？两者为什么可以不同？

2. 四条训练记录为 $x = [1, 2, 3, 4]$、$y = [0, 1, 1, 1]$。计算根节点 Gini，再分别计算阈值 1.5、2.5 的加权 Gini 和下降量，比较这两个候选。

3. 对第 3.2 节的浅树，$x = 2.5$ 与 $x = 5$ 分别到达哪个叶、预测什么类别？为什么 $x = 5$ 被判错，不代表程序没有按规则运行？

4. 一棵树在某条路径上连续判断三次才到达叶节点，这个叶的深度是多少？最大深度设为 3，是否意味着所有叶都要有这个深度？

5. 一个只有单条训练记录的纯叶，是否意味着到达这里的新对象都能预测正确？要求每叶至少两个样本，会排除哪类分裂？

6. 在相同三折下，两个候选深度的平均训练准确率分别为 0.85、0.99，平均验证准确率分别为 0.78、0.74。按预定验证规则选择哪个？确定设置后怎样训练可用模型？

7. 将输入从米改成厘米，阈值随之从 2.5 改为 250，同一批记录的子组和 Gini 是否改变？这能否推出中位数填补可以在全部开发数据上提前拟合？

8. 某叶有 10 条训练记录，其中 8 条为超限。模型给该叶估计超限概率 0.8，是否证明改变路径中的某个生产条件就能把真实超限风险减少 80%？还缺少哪类依据？

答案要点与回看位置

1. Gini 为 $1 - (1/4)^2 - (3/4)^2 = 3/8$；多数类预测的训练误判率为 1/4。Gini 根据两类比例衡量混杂，误判率根据具体类别输出计数，含义和公式不同。回看第 2.1、3.2 节。

2. 根 Gini 为 3/8。阈值 1.5 使左组 `[0]`、右组 `[1,1,1]` 都纯，加权 Gini 为 0，下降 3/8。阈值 2.5 使左组 `[0,1]`、右组 `[1,1]`，加权为 $(2/4) \times (1/2) + (2/4) \times 0 = 1/4$，下降 1/8；两个候选中选 1.5。回看第 2.2、3.1 节。

3. $x = 2.5$ 满足“不大于 2.5”，进入左叶并输出 0；$x = 5$ 进入右叶并输出 1，但已有标签为 0。规则按右叶多数类输出，一组中少数类被误判正是这种模型可能留下的拟合误差。回看第 3.2—3.3 节。

4. 深度为 3，因为从根深度 0 开始经过三条分支；最大深度是上限，其他叶可更浅。回看第 4.2 节。

5. 不能。纯只说明该叶已有训练标签相同，单条记录可能带有偶然性。最小叶样本数为 2 时，不允许产生少于两个训练样本的子叶，因此排除把单条记录单独分成一叶的划分。回看第 4.2—4.3 节。

6. 选择验证均分 0.78 的候选，不按训练分数选择。确定深度后，在全部开发记录上重新拟合填补和树；原交叉验证分数仍是选择用的证据。回看第 5.1、5.3 节。

7. 对应条件等价，分组、类别计数及 Gini 不变。但填补值仍是从数据中估计的规则，需按当前折训练范围拟合，不能由“不需标准化”推出允许全表拟合填补。回看第 5.2 节及 T07。

8. 不能。0.8 是该叶训练频率的概率估计，尚不能保证真实风险数值准确；路径反映预测关联，也不能证明改变某条件的因果效果。分别需要适当评价数据的概率可靠性检查，以及支持干预效果的额外证据。回看第 3.2、5.3 节。