T08 课堂活动：从一次划分到深度选择

姓名 _____ 班级 _____ 日期 _____

A—C 随课堂讲解完成，D 按教师安排独立作答。无需电脑，可保留分数。0 表示正常，1 表示超限；约定分裂条件成立走左，否则走右，叶节点按训练多数类预测。

A. 哪次划分使节点更纯？

本活动沿用讲义的六条抽象训练记录，先自己计算，再参与课堂核对。

样本	A	B	C	D	E	F
特征 x	1	2	3	4	5	6
标签 y	0	0	1	1	0	1

$$G = 1 - p_0^2 - p_1^2, \qquad G_{\text{split}} = \frac{n_L}{n} G_L + \frac{n_R}{n} G_R.$$

1. 根节点的两类比例和 Gini 分别是多少?
2. 分别按 $x \le 2.5$、$x \le 3.5$ 划分，填写左右标签；写出子节点 Gini 的计算步骤，再填写加权结果与下降量。

阈值	左组标签	右组标签
2.5		
3.5		

阈值	加权 Gini	下降量 $G_{\text{parent}} - G_{\text{split}}$
2.5		
3.5		

3. 两个候选中选哪个？当左右样本数不相同时，为什么不能直接把两个 Gini 等权平均?

B. 规则执行正确，仍然可能判错吗？

使用活动 A 的阈值 2.5，只分裂一次。左右叶都按各自训练标签的多数类给出预测。

输入 x	到达左叶还是右叶?	预测类别
2		
2.5		
5		

1. 补全表格。样本 E 的 $x = 5$、实际标签为 0；对它的预测是规则执行错误，还是模型按规则产生了误判？为什么?
2. 右叶的超限比例是多少？这个值是否证明所有到达右叶的新对象都有恰好相同的真实超限风险?
3. 这里的特征阈值 2.5 与把概率转成类别的阈值 0.5，分别作用于哪个量、决定什么?

C. 怎样选择树深度？

下面是另一份数据上的假设结果，与活动 A 的六行数据和实验输出无关。各候选共用相同三折、输入和准确率指标，除最大深度外，其余设置相同。

最大深度	平均训练准确率	平均折内验证准确率
1	0.72	0.70
3	0.90	0.78
8	1.00	0.71

1. 按事先规定的平均验证准确率选择，应选哪个深度？引用数值，解释为什么不选训练满分的候选。
2. 如果规定每个叶节点至少有 2 个训练样本，能否允许一次分裂产生只有 1 条记录的子节点？这个限制在约束什么？
3. “树通常不需要标准化，所以可以先用全部开发数据确定填补值，再做三折。”这句话是否正确？说明填补值应由哪部分记录确定。

D. 离堂检查：校园设备报修预测

独立作答，不与同学讨论。以下为新的合成情境，不沿用活动 C 的结果。

学校用当日使用前已知的设备状态，预测当天是否需要报修。两个候选使用相同三折及准确率指标：

最大深度	平均训练准确率	平均折内验证准确率
2	0.88	0.81
7	0.99	0.74

1. 某同学因为深度 7 的训练准确率更高而选择它。若原先约定按验证均分选择，你是否赞成？写出本次选择及理由。
2. 某棵树有一个叶节点，只包含 1 条训练记录，标签为 “需要报修”。同学据此认定：“这个叶是纯的，所以以后到这里的设备必然需要报修。” 这个结论成立吗？解释纯节点说明了什么、还没有说明什么。