T09 课堂活动：从抽样到组合判断

姓名 _____ 班级 _____ 日期 _____

A—C 随课堂讲解完成，D 按教师安排独立作答。无需电脑，可保留分数或四位小数。正常为 0，超限为 1。各树硬分类按正类概率至少为 0.5 时判为 1；概率平均选类时比较两类平均概率，本活动的类别顺序为 0、1，平票取 0。

A. 抽取次数与不同记录数

原训练样本编号为 A、B、C、D。两次有放回抽样的结果如下。

1. 补全表格，区分抽取次数与抽到的不同记录数。

抽样序列	抽取次数	不同记录数	未抽到的编号
A、A、C、D			
B、C、C、B			

2. 第一组的 A 被抽中两次，是否等于多取得了一个独立观测？说明重复使用的输入和标签来自哪里。
3. 若只把原表换个顺序，每条记录仍使用一次，会产生上面这样的重复与遗漏吗？这与有放回抽样有什么区别？

B. 多数投票与共同错误

两个对象的真实类别均为超限 1，三棵树的类别预测如下。

对象	实际类别	树 1	树 2	树 3	投票类别
A	1	1	0	1	
B	1	0	0	0	

1. 补全多数投票类别，说明哪个对象被正确识别、哪个仍然漏报。
2. 结合对象 B，解释树数增加时，怎样的判断差异才可能帮助纠正错误。
3. 把树 1 原样复制一百遍，预测时会得到独立的新判断吗？说明理由。

C. 先判类别，还是先平均概率？

下面两行是同一个问题下两个独立的概率示例，每行均有三棵树。先按本页公式和首页约定计算，再作解释。

$$\bar{p} = \frac{p_1 + p_2 + p_3}{3}, \qquad \bar{p}_{\text{normal}} = 1 - \bar{p}.$$

1. 补全两种汇总的结果。多数投票先将每棵树的概率转成类别；概率平均先计算均值，再选择平均概率较大的类别。

正类概率序列	多数投票类别	平均正类概率	概率平均类别
0.80、0.60、0.40			
0.51、0.51、0.01			

2. 第二行为什么可能得到不同类别？用具体数值说明硬票与概率平均分别保留了哪些信息。
3. 输入为计划负荷比例和环境指数，模型每到一个分裂节点随机选择一个候选特征（接口设置为 `max_features=1`）。根节点选择了环境指数后，子节点还能选择计划负荷比例吗？说明理由。

D. 离堂检查：预测打印任务是否卡纸

姓名 _____ 班级 _____ 日期 _____

独立作答，不与同学讨论。以下为新的合成情境，假设各次打印任务相互独立。模型在开始打印前，根据已知页数和纸张厚度预测本次是否卡纸。

1. 某同学把同一训练表打乱顺序 20 次，每次用全部记录训练一棵树，各节点都比较全部特征。他认为已经实施了本章随机森林的两种随机性。这个安排符合吗？分别说明训练记录和节点候选特征应怎样处理。

2. 随后按本章方式训练森林，并在相同三折、相同合法输入和指标下取得下面的假设结果。填补均在每折训练部分拟合。若事先约定按平均验证准确率选择，应选哪个？引用数值写出结论，并说明它能否保证未来所有打印任务都更好。

方案	平均折内验证准确率
单树	0.84
随机森林	0.88