T02 纸笔活动：划分与基本评价

姓名 _____ 班级 _____ 日期 _____。所有数字为教学示例，课内完成，无需设备。

A. 谁负责什么？

给 “训练”“验证”“测试” 分别匹配：拟合参数、比较候选、方案冻结后的最后检查。

判断并说明理由：

1. 查看测试误差后，修改模型直到测试误差满意，再报告这个测试分数。
2. 同一设备有多行记录，要预测从未见过的设备，随机把各行分到两边即可。
3. 要预测未来月份，用未来记录参与训练，再评价过去记录。
4. 本次只有训练与验证数据，报告 “在本次验证集上候选优于基线”，同时说明没有独立最终测试。

B. 回归误差

样本	实际值	预测值
1	10	10
2	20	18
3	30	32
4	40	36

MAE = 绝对误差之和 ÷ 样本数；RMSE = $\sqrt{\text{平方误差之和/样本数}}$。

1. 写出四行绝对误差与平方误差，计算 MAE、RMSE（可保留根号）。
2. 若目标单位为 kWh，两种指标的单位是什么？
3. 为什么不能拿模型甲的 MAE 与模型乙的 RMSE 直接判断谁更好？

C. 识别超限批次

将“超限”定义为正类，以下 100 个样本均为未用于训练的检查样本。

实际 / 预测	预测超限	预测正常
实际超限	8	2
实际正常	12	78

1. 准确率：全部样本中预测正确的比例，是多少？
2. 精确率：预测超限的样本中实际超限的比例，是多少？
3. 召回率：实际超限的样本中被识别的比例，是多少？
4. 全部预测正常的基线准确率是多少？它能识别多少超限？
5. 若漏掉超限的代价很高，你会优先关注什么？是否意味着误报可以完全不考虑？

D. 该相信哪个分数？

下表为假设情境，三个方法使用相同训练/验证划分和 MAE。方法乙的原理本讲不考查。

方法	训练 MAE	验证 MAE
简单基线	60	65
候选甲	12	15
候选乙	0	40

1. 当前更有依据选择哪个候选，为什么？
2. 乙的训练误差为 0，为什么仍不能宣布它最好？
3. 若甲改用了更容易的验证样本，再把新分数与乙的旧分数比较，是否公平？
4. 当前结果能否直接称为最终测试表现？

E. 离堂检查

某同学说：“训练误差最低的模型一定最好；测试集可以反复看，直到找到最高分。”请指出两处问题，并各写一句正确做法。