# T01 纸笔活动：任务、数据与基线

姓名：_____ 班级：_____ 日期：_____

课内完成，无需电脑。所有数据均为合成教学示例。

## A. 入口短诊断

某厂想在每个批次开工前估计该批次完工后的总能耗。

1. 数据表的一行应该代表什么？
2. 已有四个批次能耗为 100、150、250、300 kWh，均值是多少？
3. 不写程序：如果需要将 “计划产量” 作为输入，你会选择一列还是一行？

## B. 辨认任务

分别写 “回归”“分类” 或 “聚类”，并说明输出是什么。

| 情境 | 任务与输出 |
| --- | --- |
| 开工前预测一个批次的总能耗 | |
| 根据已标注的历史记录，预测某批次是否会超出规定能耗限额 | |
| 没有预先给定类别，把能耗模式相似的批次分组 | |
| 数据表用 0 代表正常、1 代表超限，预测这个编码 | |

## C. 数据与预测时点

假设计划产量在开工前确定，总能耗和最终电费在完工后才取得。

| 批次编号 | 用途 | 计划产量（件） | 总能耗（kWh） |
|---|---|---|---|
| H1 | 历史记录 | 20 | 100 |
| H2 | 历史记录 | 40 | 150 |
| H3 | 历史记录 | 80 | 250 |
| H4 | 历史记录 | 100 | 300 |
| N1 | 新批次，完工后核对 | 60 | 230 |
| N2 | 新批次，完工后核对 | 110 | 320 |

1. 在“计划产量、总能耗、最终电费、批次编号”中，选择本情境的主要输入和标签。说明另外两列的处理依据。
2. 补全任务说明：在 _____ 时，以一个 _____ 为样本，使用 _____，预测 _____。
3. 表中已经列出了 N1/N2 的实际能耗，是否表示开工前可以把它们作为输入？为什么？

## D. 一个简单基线

只用 H1—H4 的能耗均值，对每个新批次预测同一个数。另有一个给定候选，其 N1/N2 预测值分别为 210、310 kWh。本题只比较预测结果，不研究候选如何得到。

| 新批次 | 实际能耗 | 基线预测 | 基线绝对误差 | 候选预测 | 候选绝对误差 |
|---|---|---|---|---|---|
| N1 | 230 | | | 210 | |
| N2 | 320 | | | 310 | |

绝对误差 = 预测值与实际值之差的绝对值；平均绝对误差 = 两行绝对误差之和 ÷2，单位 kWh。

1. 两种方法的平均绝对误差分别是多少?
2. 哪个方法在这两行上表现更好？这个结果能说明它对未来所有批次都更好吗?
3. 能否把 N1/N2 的实际值加入均值计算后，再声称这是开工前可用的基线?

## E. 90% 就够好吗？

另一个分类案例：历史批次中正常类占多数。我们预先选定“全部预测正常”的简单基线；在随后 100 个检查样本中，实际 90 个正常、10 个超限。

这个基线预测对了多少个？有没有识别出超限批次？如果超限会导致严重损失，你还想知道模型的什么表现?

## F. 离堂检查（独立完成）

快递站要在每天开门前预测当天到站的包裹总件数。此时已知前一天到站件数和当天已登记的运输车次；当天关门后才能统计未取包裹件数。

1. 写明预测时点和预测目标，并指出一项不能作为输入的字段及原因。
2. 给出一种开门前可执行的简单基线。
3. 用一句话解释：为什么正式模型需要与基线比较？